

**Notas de aula
2005**

NOÇÕES PRÁTICAS DE TÉCNICAS DE ESTIMAÇÃO

Hélio Koiti Kuga

Instituto Nacional de Pesquisas Espaciais – INPE
Cx. Postal 515 – São José dos Campos, SP
CEP 12201 – 970

E-Mail: hkk@dem.inpe.br
Internet: <http://www2.dem.inpe.br/hkk/>

CONTEÚDO

1 - INTRODUÇÃO

- 1.1 - Objetivo
- 1.2 - Ênfase

2 - ESTIMAÇÃO DE PARÂMETROS

- 2.1 - Mínimos quadrados
 - 2.1.1 - Mínimos quadrados em lotes
 - 2.1.2 - Mínimos quadrados recursivo
 - 2.1.3 - Mínimos quadrados ponderado
 - 2.1.4 - Mínimos quadrados com informação a-priori
- 2.2 - Exemplo de aplicação 1
 - 2.2.1 - Solução direta
 - 2.2.2 - Solução com ponderação
 - 2.2.3 - Solução com informação a-priori
 - 2.2.4 - Solução recursiva
- 2.3 - Exercícios

3 - ESTIMAÇÃO LINEAR DE ESTADOS

- 3.1 - Modelagem da dinâmica do estado (caso discreto)
- 3.2 - Modelagem das observações (caso discreto)
- 3.3 - Mínimos quadrados
 - 3.3.1 - Processamento em lotes ("batch")
 - 3.3.2 - Processamento recursivo (forma de Kalman)
- 3.4 - Filtro de Kalman
 - 3.4.1 - Fase de propagação (predição)
 - 3.4.2 - Fase de atualização (correção)
 - 3.4.3 - Caso contínuo-discreto (discretização)
 - 3.4.4 - Sobre a matriz de transição
- 3.5 - Exemplo de aplicação 2
 - 3.5.1 - Solução pelo filtro de Kalman
 - 3.5.2 - Solução por mínimos quadrados
- 3.6 - Exercícios

4 - ESTIMAÇÃO NÃO-LINEAR DE ESTADOS

- 4.1 - Linearização da dinâmica contínua
- 4.2 - Linearização das medidas discretas
- 4.3 - Discretização da dinâmica contínua não-linear
- 4.3 - Mínimos quadrados não-linear
- 4.5 - Filtro linearizado e estendido de Kalman
 - 4.5.1 - Filtro linearizado
 - 4.5.2 - Filtro estendido
- 4.6 - Exemplo de aplicação 3

1. INTRODUÇÃO

Este texto foi elaborado visando um curso de curta duração, versando sobre o tema "**NOÇÕES PRÁTICAS DE TÉCNICAS DE ESTIMAÇÃO**". A título de observação, o autor esclarece que o material do curso tende a ser menos informal na teoria e enfático na aplicação prática.

1.1 Objetivo

O curso pretende fornecer noções práticas sobre a utilização de técnicas de estimação envolvendo Mínimos Quadrados e Filtro de Kalman. Ele está estruturado de forma a permitir um projeto de software utilizando tais técnicas, assumindo conhecimento teórico prévio mínimo.

1.2 Ênfase

Ênfase será dada à utilização prática, sem grandes preocupações teóricas. O material a ser exposto pressupõe algum conhecimento básico de álgebra de matrizes, noções de estatística, e familiaridade com computador.

2. ESTIMAÇÃO DE PARÂMETROS

Estimar parâmetros significa, como o próprio nome diz, estimar *coisas* que não variam, são constantes ao longo do processo de estimação. É evidente que se necessita medir direta ou indiretamente o que se deseja estimar. Então, para começar a estimar *algo*, necessita-se de um conjunto de medidas que esteja relacionada a esse *algo*. O próximo passo é modelar como essas medidas se relacionam aos parâmetros a serem estimados. Essa fase necessita de engenho, arte e experiência do experimentador. Isso, nenhum curso pode proporcionar, só a vivência prática e consequente amadurecimento poderão!

2.1 Mínimos quadrados

Um dos estimadores de parâmetros mais utilizado pela comunidade científica é o algoritmo de mínimos quadrados. Este procedimento é tão antigo quanto Gauss que primeiro o formulou para processar observações astronômicas de corpos celestes. Formalmente, o algoritmo trata de minimizar uma função custo (perda, índice de desempenho) do quadrado dos resíduos (vêm daí a razão do nome) na forma:

$$L = (\mathbf{y} - \mathbf{H}\mathbf{x})' (\mathbf{y} - \mathbf{H}\mathbf{x}) \quad (2.1)$$

ou na notação de norma vetorial:

$$L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 \quad (2.2)$$

onde y representa o vetor contendo m medidas, x representa o vetor de n parâmetros a serem estimados, e H é uma matriz $m \times n$ que relaciona as medidas aos parâmetros.

Seja, por exemplo, o caso de ajustar uma reta aos dados, através do método de mínimos quadrados, conforme ilustrado na Figura 2.1.




Fig. 2.1 - Ajuste linear

A equação genérica da reta é dada por $y_i = at_i + b$. Logo, a equação que relaciona as medidas aos parâmetros é formulada como:

$$y = Hx \quad (2.3)$$

ou, de modo explícito:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{m1} \end{bmatrix} = \begin{bmatrix} t_1 & 1 \\ t_2 & 1 \\ \vdots & \vdots \\ t_m & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \quad (2.4)$$

onde $x = (a, b)$ é o vetor que contém os parâmetros a serem estimados.

2.1.1 Mínimos quadrados em lotes

Continuaremos com o exemplo para ilustrar e fixar idéias. Em princípio, a forma mais direta de processar essas medidas é o chamado processamento em lotes ("batch"). Passemos à análise desse exemplo. Lembrando que m é o número de medidas:

- $m = 1 \Rightarrow$ então solução indeterminada, lembrando que por um ponto passam infinitas retas.
- $m = 2$ então ficamos com:

$$\begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} t_1 & 1 \\ t_2 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \quad (2.5)$$

cuja solução é imediata:

$$\begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} t_1 & 1 \\ t_2 & 1 \end{bmatrix}^{-1} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \quad (2.6)$$

Se $t_1 \rightarrow t_2$ a matriz $\mathbf{H}$ tende a ser singular!!!

- $m > 2$ então ficamos com a solução clássica de mínimos quadrados, também chamada de equação normal:

$$\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} \quad (2.7)$$

Este último caso, que é o que nos interessa, resolve o problema através da formulação "batch", em lotes. Em outras palavras, este algoritmo processa as medidas todas de uma só vez.

A noção de covariância deve ser incluída aqui. Covariância é a matriz $\mathbf{P} = (\mathbf{H}^T \mathbf{H})^{-1}$ que dá uma idéia do erro nas estimativas. Compõe-se de variâncias e correlações:

$$\mathbf{P} = (\mathbf{H}^T \mathbf{H})^{-1} = \begin{bmatrix} \sigma_a^2 & \sigma_{ab} \\ \sigma_{ab} & \sigma_b^2 \end{bmatrix} \quad (2.8)$$

onde σ^2 é o quadrado do desvio-padrão (variância), e σ_{ab} é o coeficiente de correlação entre a e b .

A covariância deve ser sempre definida positiva, ou seja, ser inversível, não-singular, para que possa existir a solução de mínimos quadrados.

2.1.2 Mínimos quadrados recursivo

O algoritmo de mínimos quadrados recursivo nada mais é do que uma forma algebricamente equivalente de processar as medidas. A vantagem desse algoritmo, aplicado à estimação de parâmetros, reside no fato de evitar inversões de matrizes. Diz-se recursivo por ter características de recursividade, portanto, bastante adequados para programação em computador. Outra vantagem é a de necessitar de matrizes de menor dimensão, traduzindo-

se em menos memória de armazenamento. Basicamente, o algoritmo usa a forma de *Kalman* para o processamento.

Primeiro, para fins didáticos, particionam-se as matrizes envolvidas:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} t_1 & 1 \\ t_2 & 1 \\ \vdots & \vdots \\ t_m & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \mathbf{H}_1 \\ \mathbf{H}_2 \\ \vdots \\ \mathbf{H}_m \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \quad (2.9)$$

onde os $\mathbf{H}_i$ são os vetores linha que compõe a matriz $\mathbf{H}$.

Para iniciar, calcula-se:

$$\mathbf{P}_2 = \left(\begin{bmatrix} \mathbf{H}_1^t & \mathbf{H}_2^t \end{bmatrix} \begin{bmatrix} \mathbf{H}_1 \\ \mathbf{H}_2 \end{bmatrix} \right)^{-1} \quad (2.10)$$

$$\hat{\mathbf{x}}_2 = \mathbf{P}_2 \begin{bmatrix} \mathbf{H}_1^t & \mathbf{H}_2^t \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$$

em seguida, o algoritmo torna-se recursivo para $i = 3, \dots, m$:

$$\begin{aligned} \mathbf{K}_i &= \mathbf{P}_{i-1} \mathbf{H}_i^t (\mathbf{H}_i \mathbf{P}_{i-1} \mathbf{H}_i^t + 1)^{-1} \\ \mathbf{P}_i &= (\mathbf{I} - \mathbf{K}_i \mathbf{H}_i) \mathbf{P}_{i-1} \\ \hat{\mathbf{x}}_i &= \hat{\mathbf{x}}_{i-1} + \mathbf{K}_i (y_i - \mathbf{H}_i \hat{\mathbf{x}}_{i-1}) \end{aligned} \quad (2.11)$$

2.1.3 Mínimos quadrados ponderado

Introduz-se agora a noção de ponderação. A analogia é semelhante à média aritmética simples em relação à média aritmética ponderada. Se existem vários equipamentos de medida para realizar as medidas, ou se existem diferentes tipos de medidas, é natural que essas medidas tenham erros diferentes. Para contornar essa dificuldade, usa-se o critério de mínimos quadrados com ponderação das medidas. A função custo, neste caso, torna-se:

$$L = (\mathbf{y} - \mathbf{H}\mathbf{x})^t \mathbf{W} (\mathbf{y} - \mathbf{H}\mathbf{x}) = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|_{\mathbf{W}}^2 \quad (2.12)$$

onde $\mathbf{W}$ é a matriz de peso que pondera os diferentes tipos de erros. Usualmente define-se:

$$\mathbf{W} = \begin{bmatrix} 1/\sigma_1^2 & 0 & \dots & 0 \\ 0 & 1/\sigma_2^2 & \dots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & \dots & 1/\sigma_m^2 \end{bmatrix} \quad (2.13)$$

onde $\sigma_i, i=1, \dots, m$ é o desvio-padrão da medida i . Quanto menor o σ_i , mais precisa e maior o peso que a medida correspondente terá no processo de estimação. Neste caso, a solução de mínimos quadrados com ponderação é dada por:

$$\hat{\mathbf{x}} = (\mathbf{H}'\mathbf{W}\mathbf{H})^{-1} \mathbf{H}'\mathbf{W}\mathbf{y} \quad (2.14)$$

onde a covariância $\mathbf{P}$ é dada pelo fator:

$$\mathbf{P} = (\mathbf{H}'\mathbf{W}\mathbf{H})^{-1} \quad (2.15)$$

2.1.4 Mínimos quadrados com informação a-priori

O último passo na linha de estimação de parâmetros linear é a introdução da informação a-priori. A informação a-priori significa que se tem algum conhecimento inicial dos valores dos parâmetros a serem estimados. Na teoria de estimação linear este fato não é importante, mas em sistemas não-lineares torna-se fundamental para se obter rápida convergência do algoritmo. A informação a-priori é caracterizada pelo chute inicial no valor do estado e na incerteza (covariância) sobre esse chute inicial. Neste caso a função custo incorpora essa informação da seguinte forma:

$$L = (\mathbf{y} - \mathbf{H}\mathbf{x})' \mathbf{W} (\mathbf{y} - \mathbf{H}\mathbf{x}) + (\mathbf{x} - \hat{\mathbf{x}}_o)' \mathbf{P}_o^{-1} (\mathbf{x} - \hat{\mathbf{x}}_o) \quad (2.16)$$

ou na notação através de norma, a função custo assume a forma:

$$L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|_{\mathbf{W}}^2 + \|\mathbf{x} - \hat{\mathbf{x}}_o\|_{\mathbf{P}_o^{-1}}^2 \quad (2.17)$$

onde $\hat{\mathbf{x}}_o$ é o vetor contendo os valores do chute inicial, e $\mathbf{P}_o$ é a matriz de covariância inicial que usualmente é inicializada por:

$$\mathbf{P}_o^{-1} = \begin{bmatrix} 1/\sigma_{\hat{\mathbf{x}}_o(1)}^2 & 0 & \dots & 0 \\ 0 & 1/\sigma_{\hat{\mathbf{x}}_o(2)}^2 & \dots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & \dots & 1/\sigma_{\hat{\mathbf{x}}_o(n)}^2 \end{bmatrix} \quad (2.18)$$

onde os $\sigma_{\hat{\mathbf{x}}_o}$ representam os desvios-padrão (incertezas) nos valores iniciais. Notar que se $\mathbf{P}_o^{-1} \rightarrow 0$, significando que a incerteza é infinita, então os valores do chute inicial $\hat{\mathbf{x}}_o$ são irrelevantes pois o problema se reduz ao mínimos quadrados ponderado sem informação a-priori. A solução de mínimos quadrados ponderado, com informação a-priori, é dada por:

$$\hat{\mathbf{x}} = \mathbf{P}(\mathbf{P}_o^{-1}\hat{\mathbf{x}}_o + \mathbf{H}'\mathbf{W}\mathbf{y}) \quad (2.19)$$

onde $\mathbf{P}$ é a covariância dada por:

$$\mathbf{P} = (\mathbf{P}_o^{-1} + \mathbf{H}'\mathbf{W}\mathbf{H})^{-1} \quad (2.20)$$

Então, a forma recursiva, forma de Kalman, é dada pelo seguinte "loop" para $i = 1, \dots, m$:

$$\begin{aligned} \mathbf{K}_i &= \mathbf{P}_{i-1} \mathbf{H}_i' (\mathbf{H}_i \mathbf{P}_{i-1} \mathbf{H}_i' + 1/w_i)^{-1} \\ \mathbf{P}_i &= (\mathbf{I} - \mathbf{K}_i \mathbf{H}_i) \mathbf{P}_{i-1} \\ \hat{\mathbf{x}}_i &= \hat{\mathbf{x}}_{i-1} + \mathbf{K}_i (y_i - \mathbf{H}_i \hat{\mathbf{x}}_{i-1}) \end{aligned} \quad (2.21)$$

onde w_i é a i -ésima componente da diagonal da matriz de peso (ponderação) $\mathbf{W}$, equação 2.13. Nota-se que, neste caso, o algoritmo é recursivo do início ao fim. Uma vez tendo o chute inicial $\hat{\mathbf{x}}_o$ e $\mathbf{P}_o$, necessita-se um "loop" para processar as m medidas uma de cada vez.

2.2 Exemplo de aplicação 1

Seja o exemplo de se ajustar uma reta aos dados. Suponha que tenhamos a Tabela 2.1 de dados coletados. A solução exata é óbvia, é uma reta passando pela origem com 45° de inclinação; ou seja, os coeficientes da reta valem exatamente $a=1$ e $b=0$.

Tabela 2.1
Dados para o exemplo de aplicação

Tempo	Medida	Desvio-padrão
1	1.03	0.05
2	1.95	0.06
3	2.40	0.70
4	4.03	0.08

2.2.1 Solução direta

Neste caso, não usamos a informação sobre os desvios-padrão, supondo que todos os dados tem a mesma precisão. Definimos $\mathbf{x} = (a, b)$, $\mathbf{y} = (1.03, 1.95, 2.40, 4.03)$ e a matriz $\mathbf{H}$ vale:

$$\mathbf{H} = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{bmatrix}$$

Se usarmos somente as duas primeiras medidas, ficamos com $a=0.92$ e $b=0.11$ (Faça as contas!). Usando todos os dados, e aplicando a Equação 2.7 temos:

$$\mathbf{P} = \begin{bmatrix} 0.4472^2 & -0.5 \\ -0.5 & 1.2247^2 \end{bmatrix}$$

e daí:

$$\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix} = \begin{bmatrix} 0.9450 \\ -0.0100 \end{bmatrix}$$

Notar que apesar do resultado ser satisfatório, a informação dada pela covariância não é!!! Qual será a causa? O resultado deve ser interpretado como sendo:

$$\hat{a} = 0.9450 \pm 0.4472$$

$$\hat{b} = -0.0100 \pm 1.2247$$

2.2.2 Solução com ponderação

A diferença agora é a consideração dos erros das medidas. A matriz $\mathbf{W}$ é definida por:

$$\mathbf{W} = \begin{bmatrix} 1/0.05^2 & 0 & 0 & 0 \\ 0 & 1/0.06^2 & 0 & 0 \\ 0 & 0 & 1/0.70^2 & 0 \\ 0 & 0 & 0 & 1/0.08^2 \end{bmatrix}$$

Usando agora as Equações 2.14 e 2.15 temos o seguinte resultado:

$$\mathbf{P} = \begin{bmatrix} 0.0316^2 & -0.0019 \\ -0.0019 & 0.0686^2 \end{bmatrix}$$

e daí:

$$\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix} = \begin{bmatrix} 0.9964 \\ 0.0088 \end{bmatrix} \pm \begin{bmatrix} 0.0316 \\ 0.0686 \end{bmatrix}$$

Nota-se agora uma consistência muito maior entre as estimativas e os valores verdadeiros.

2.2.3 Solução com informação a-priori

Suponha que nós tenhamos um sentimento, um chute inicial para os valores iniciais dos parâmetros, por exemplo:

$$\hat{a} = 1.2 \pm 0.4$$

$$\hat{b} = -0.1 \pm 0.1$$

Então nossa matriz de covariância inicial será:

$$\mathbf{P}_o = \begin{bmatrix} 0.4^2 & 0 \\ 0 & 0.1^2 \end{bmatrix}$$

e o chute inicial dos parâmetros é:

$$\hat{\mathbf{x}}_o = \begin{bmatrix} 1.2 \\ -0.1 \end{bmatrix}$$

Aplicando as Equações 2.19 e 2.20 teremos o seguinte resultado:

$$\mathbf{P} = \begin{bmatrix} 0.0273^2 & -0.0013 \\ -0.0013 & 0.0566^2 \end{bmatrix}$$

e daí:

$$\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix} = \begin{bmatrix} 1.0110 \\ -0.0277 \end{bmatrix} \pm \begin{bmatrix} 0.0273 \\ 0.0566 \end{bmatrix}$$

2.2.4 Solução recursiva

Nesta aplicação iremos utilizar a forma recursiva conforme a Equação 2.21. A Tabela 2.2 mostra os resultados dos cálculos passo a passo.

Tabela 2.2
Solução utilizando a forma de Kalman

t	$HPH^t + 1/w$	K_1	K_2	resíduo	$\hat{a}$	$\hat{b}$	σ_a^2	σ_b^2
1	0.1725	0.9275	0.0580	-0.0700	1.1351	-0.1041	0.0116	0.0094
2	0.0223	0.6240	-0.4095	-0.2161	1.0002	-0.0456	0.0029	0.0057
3	0.5004	0.0103	-0.0161	-0.5851	0.9942	-0.0097	0.0029	0.0056
4	0.0296	0.2675	-0.2865	0.0629	1.0110	-0.0277	0.0007	0.0032

Nota-se que o resultado final é exatamente o mesmo que a solução dada pelo mínimos quadrados em lote, como era de se esperar!!!

A Figura 2.2 plota as estimativas e respectivos desvios-padrão σ , e a Figura 2.3 plota os resíduos resultantes do processo de estimação através da forma de Kalman.




Fig. 2.2 - Estimativas dos parâmetros e desvios-padrão




Fig. 2.3 - Resíduos

2.3 Exercícios

1) Usando os dados da Tabela 2.1, ajustar agora uma parábola, para os seguintes casos:

- Mínimos quadrados
- Mínimos quadrados ponderado
- Mínimos quadrados ponderado com informação a priori
- O item c, mas com a formulação recursiva

Para a informação a priori, assumir que o coeficiente do termo de segundo grau tem desvio-padrão de 0.1. Qual seria um chute inicial para o valor deste coeficiente?

2) Dada a função custo

$$L = \|y - Hx\|^2 = (y - Hx)^t (y - Hx)$$

minimizar L em relação a x .

3) dados $\hat{x}_o$ e P_o (informação a priori), provar que $\hat{x}$ pode ser estimado através da forma de Kalman:

$$\begin{aligned} K &= P_o H^t (H P_o H^t + R)^{-1} \\ P &= (I - KH) P_o \\ \hat{x} &= \hat{x}_o + K(y - H\hat{x}_o) \end{aligned}$$

onde

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix},$$

$$H = \begin{bmatrix} H_1 \\ H_2 \\ \vdots \\ H_m \end{bmatrix} = \begin{bmatrix} H_1 \\ H_2 \\ \vdots \\ H_m \end{bmatrix} = \begin{bmatrix} H_{11} & H_{12} & \cdots & H_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ H_{m1} & H_{m2} & \cdots & H_{mn} \end{bmatrix},$$

$$R^{-1} = W = \begin{bmatrix} 1/\sigma_1^2 & 0 & \cdots & 0 \\ 0 & 1/\sigma_2^2 & \cdots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & \cdots & 1/\sigma_m^2 \end{bmatrix}$$

3. ESTIMAÇÃO LINEAR DE ESTADOS

O que é estado? Qual a diferença em estimar parâmetros ou estados? A diferença é que o estado é dinâmico, varia ao longo do processo de estimação. Significa que deve-se incluir no processo de estimação um modelo para essa variação. Quanto melhor esse modelo, mais confiáveis serão os resultados obtidos. Esse modelo utiliza normalmente o conhecimento sobre o estado a ser estimado, traduzido através de modelos matemáticos do fenômeno físico. Começa-se com o estudo do caso linear, isto é, o estado varia linearmente, e as medidas ou observações se relacionam linearmente com o estado.

3.1 Modelagem da dinâmica do estado (caso discreto)

A modelagem do estado, isto é, das variáveis que deverão ser estimadas é, para o caso discreto (variando em instantes discretos), formalmente dada por:

$$\mathbf{x}_{k+1} = \boldsymbol{\varphi}_{k+1,k} \mathbf{x}_k + \boldsymbol{\Gamma}_k \boldsymbol{\omega}_k \quad (3.1)$$

onde $\mathbf{x}$ é o vetor de n -estados a ser estimado, $\boldsymbol{\varphi}$ é a matriz $n \times n$ de transição (ou matriz fundamental), $\boldsymbol{\Gamma}$ é a matriz $n \times p$ de adição do ruído dinâmico, e $\boldsymbol{\omega}$ é o vetor de ruído branco discreto de dimensão p .

A matriz $\boldsymbol{\varphi}_{k+1,k}$ modela matematicamente a maneira pela qual o estado varia do instante t_k para o instante t_{k+1} . O vetor $\boldsymbol{\omega}$ representa a parte estatística, estocástica, da equação, que tem por objetivo modelar as flutuações, erros no modelo, e outros de natureza aleatória ou impossíveis de serem modelados. Essa equação é usualmente chamada de equação estocástica por conter uma parte determinística e uma parte estatística. A parte estatística, modelada como um ruído branco, tem as seguintes estatísticas:

$$\begin{aligned} E[\boldsymbol{\omega}_k] &= \mathbf{0} \\ E[\boldsymbol{\omega}_k \boldsymbol{\omega}_j^t] &= \mathbf{Q}_k \delta_{kj} \end{aligned} \quad (3.2)$$

onde E representa o operador esperança, $\mathbf{Q}_k$ é a matriz $p \times p$ de covariância do ruído dinâmico, e δ_{kj} é o delta de Kronecker que vale 1 quando $k = j$ e 0 para $k \neq j$. Estas equações fornecem a média (primeiro momento) e a covariância (segundo momento) do processo de ruído branco. Elas podem ser também representadas por:

$$\boldsymbol{\omega}_k = N(\mathbf{0}, \mathbf{Q}_k) \quad (3.3)$$

que pode ser lido do seguinte modo: "A variável aleatória $\boldsymbol{\omega}_k$ tem uma distribuição normal de média $\mathbf{0}$ e covariância $\mathbf{Q}_k$ ".

3.2 Modelagem das observações (caso discreto)

O modelo das observações (medidas) já foi grosseiramente dado pela equação 2.3. Agora, formalizar-se-á este modelo completamente, para o caso linear discreto:

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k \quad (3.4)$$

onde $\mathbf{y}$ é o vetor de m observações coletadas, $\mathbf{H}$ é a matriz $m \times n$ relacionando as observações ao estado, e $\mathbf{v}$ é o vetor de m ruídos brancos discretos.

A matriz $\mathbf{H}$ modela como as observações se relacionam ao estado. Neste caso a relação é linear, e normalmente é uma matriz de constantes. O vetor de ruído branco $\mathbf{v}$ modela os erros de natureza aleatória cometidos durante a realização das respectivas observações. Analogamente ao ruído dinâmico, ele é modelado por:

$$\begin{aligned} E[\mathbf{v}_k] &= \mathbf{0} \\ E[\mathbf{v}_k \mathbf{v}_j^t] &= \mathbf{R}_k \delta_{kj} \end{aligned} \quad (3.5)$$

onde $\mathbf{R}$ é a matriz $m \times m$ da covariância dos erros de observações, e δ_{kj} é o delta de Kronecker. A similaridade com a matriz de ponderação $\mathbf{W}$ (veja Seção 2.1.4) não é forçada, é natural!! A matriz $\mathbf{R}$ contém as variâncias (lembre-se, são os quadrados dos desvios-padrão) em sua diagonal.

$$\mathbf{W} = \begin{bmatrix} 1/\sigma_1^2 & 0 & \cdots & 0 \\ 0 & 1/\sigma_2^2 & \cdots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & \cdots & 1/\sigma_m^2 \end{bmatrix} \Rightarrow \mathbf{R} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & \cdots & \sigma_m^2 \end{bmatrix} \quad (3.6)$$

3.3 Mínimos quadrados

Como o processo de mínimos quadrados é utilizado para estimar estados, linearmente variantes no tempo? Deve-se incorporar ao processo o modelo dinâmico. No caso do mínimos quadrados, a equação dinâmica é puramente determinística, não se inclui a parte estatística, não se considera ruído dinâmico. Em outras palavras, supõe-se que o modelo dinâmico é exato. A solução é obtida para um determinado instante de referência denominado época. Seja o problema de estimar o estado no instante t_o , dados um chute inicial $\hat{\mathbf{x}}_o$ e respectiva incerteza (covariância) $\mathbf{P}_o$, e m -medidas realizadas em instantes t_k , dentro do intervalo $0 \leq t_k \leq t_f$. Novamente, existem duas maneiras de se obter a solução de mínimos quadrados: em lotes e recursivamente. Vamos a elas.

3.3.1 Processamento em lotes ("batch")

O processamento é praticamente igual à estimação de parâmetros, com exceção da introdução da dinâmica de estado. Inicia-se modelando como o estado se relaciona às medidas, para o instante de referência, lembrando que:

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k$$

Seja o instante de referência ou época t_o para a qual se deseja as estimativas de $\mathbf{x}_o$. Como o estado $\mathbf{x}_k$ se relaciona entre instantes por $\mathbf{x}_{k+1} = \boldsymbol{\varphi}_{k+1,k} \mathbf{x}_k$ (veja Equação 3.1) então pode-se escrever (Lembre-se que o mínimos quadrados não considera a parcela $\boldsymbol{\omega}_k$ de ruído dinâmico):

$$\begin{aligned} \mathbf{x}_1 &= \boldsymbol{\varphi}_{1,0} \mathbf{x}_o \\ \mathbf{x}_2 &= \boldsymbol{\varphi}_{2,1} \mathbf{x}_1 \\ &\vdots \\ \mathbf{x}_m &= \boldsymbol{\varphi}_{m,m-1} \mathbf{x}_{m-1} \end{aligned} \tag{3.7}$$

onde $\boldsymbol{\varphi}_{k+1,k}$ é a matriz de transição que relaciona o estado entre os instantes t_{k+1} e t_k . Uma propriedade importante desta matriz é a seguinte:

$$\boldsymbol{\varphi}_{k+1,k-1} = \boldsymbol{\varphi}_{k+1,k} \boldsymbol{\varphi}_{k,k-1} \tag{3.8}$$

donde se conclui que:

$$\begin{aligned} \mathbf{x}_1 &= \boldsymbol{\varphi}_{1,0} \mathbf{x}_o \\ \mathbf{x}_2 &= \boldsymbol{\varphi}_{2,0} \mathbf{x}_o \\ &\vdots \\ \mathbf{x}_m &= \boldsymbol{\varphi}_{m,0} \mathbf{x}_o \end{aligned} \tag{3.9}$$

Logo, a equação de observações pode ser escrita em função do estado $\mathbf{x}_o$ da época t_o , ou seja:

$$\mathbf{y} = \mathbf{H} \mathbf{x}_o + \mathbf{v} \tag{3.10}$$

onde:

$$\mathbf{y} = \begin{bmatrix} y_{t_1} \\ y_{t_2} \\ \vdots \\ y_{t_m} \end{bmatrix} \tag{3.11}$$

$$\mathbf{H} = \begin{bmatrix} \mathbf{H}_{t_1} \boldsymbol{\phi}_{1,0} \\ \mathbf{H}_{t_2} \boldsymbol{\phi}_{2,0} \\ \vdots \\ \mathbf{H}_{t_m} \boldsymbol{\phi}_{m,0} \end{bmatrix} \quad (3.12)$$

$$\mathbf{v} = \begin{bmatrix} v_{t_1} \\ v_{t_2} \\ \vdots \\ v_{t_m} \end{bmatrix} \quad (3.13)$$

Agora, é só aplicar as equações para solução por mínimos quadrados dada na Seção 2.1.4, com alguns retoques na notação (infelizmente a complexidade na notação vai aumentando conforme se desenvolve a teoria). Nominalmente:

- covariância:

$$\hat{\mathbf{P}}_{t_o} = (\bar{\mathbf{P}}_{t_o}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \quad (3.14)$$

- estado:

$$\hat{\mathbf{x}}_{t_o} = \hat{\mathbf{P}}_{t_o} (\bar{\mathbf{P}}_{t_o}^{-1} \bar{\mathbf{x}}_{t_o} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{y}) \quad (3.15)$$

onde agora $\bar{\mathbf{x}}_{t_o}$ e $\bar{\mathbf{P}}_{t_o}$ representam a informação a-priori, ou seja, o estado e a covariância inicial; e $\hat{\mathbf{x}}_{t_o}$ e $\hat{\mathbf{P}}_{t_o}$ representam o estado e a covariância após o processamento de todas as m -observações. A matriz $\mathbf{R}$ diagonal faz o papel da inversa da matriz de ponderação $\mathbf{W}$ e é definida por:

$$\mathbf{R} = \begin{bmatrix} R_{t_1} & 0 & \cdots & 0 \\ 0 & R_{t_2} & \cdots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & \cdots & R_{t_m} \end{bmatrix} \quad (3.16)$$

3.3.2 Processamento recursivo (forma de Kalman)

Uma vez entendido o mecanismo de se adicionar o efeito da dinâmica do estado no processo de estimação, torna-se trivial usar o processamento recursivo. Analogamente ao caso de estimação de parâmetros, uma vez dada a informação a-priori $\bar{\mathbf{x}}_{t_o}$ e $\bar{\mathbf{P}}_{t_o}$, particiona-se a matriz $\mathbf{H}$ convenientemente:

$$\mathbf{H} = \begin{bmatrix} \mathbf{H}_{t_1} \boldsymbol{\phi}_{1,0} \\ \mathbf{H}_{t_2} \boldsymbol{\phi}_{2,0} \\ \vdots \\ \mathbf{H}_{t_m} \boldsymbol{\phi}_{m,0} \end{bmatrix} = \begin{bmatrix} \mathbf{H}_1 \\ \mathbf{H}_2 \\ \vdots \\ \mathbf{H}_m \end{bmatrix} \quad (3.17)$$

O processo parte dos valores de $\hat{\mathbf{x}}_o \leftarrow \bar{\mathbf{x}}_{t_o}$ e $\hat{\mathbf{P}}_o \leftarrow \bar{\mathbf{P}}_{t_o}$ e processa as m -observações através de um "loop" com $i = 1, \dots, m$:

$$\begin{aligned} \mathbf{K}_i &= \hat{\mathbf{P}}_{i-1} \mathbf{H}_i^t \left(\mathbf{H}_i \hat{\mathbf{P}}_{i-1} \mathbf{H}_i^t + \mathbf{R}_i \right)^{-1} \\ \hat{\mathbf{P}}_i &= (\mathbf{I} - \mathbf{K}_i \mathbf{H}_i) \hat{\mathbf{P}}_{i-1} \\ \hat{\mathbf{x}}_i &= \hat{\mathbf{x}}_{i-1} + \mathbf{K}_i (\mathbf{y}_i - \mathbf{H}_i \hat{\mathbf{x}}_{i-1}) \end{aligned} \quad (3.18)$$

Ao final do "loop", $\hat{\mathbf{x}}_{t_o} \leftarrow \hat{\mathbf{x}}_m$ e $\hat{\mathbf{P}}_{t_o} \leftarrow \hat{\mathbf{P}}_m$.

3.4 Filtro de Kalman

Agora que aprendemos como usar a forma recursiva, isto é, a forma de Kalman para achar a solução por mínimos quadrados, iremos achar a solução pelo filtro de Kalman. O que é diferente agora? Duas são as diferenças marcantes em relação ao método de mínimos quadrados:

- O filtro de Kalman pode incorporar ruído dinâmico no modelo da dinâmica do estado (na verdade já existem os estimadores de pseudo-época que podem incorporar tal ruído, mas isto é assunto para tópicos super avançados),
- O filtro de Kalman é um estimador com características de tempo real, ou seja, ele fornece as estimativas para o instante em que a medida é processada.

Resumindo, o filtro de Kalman pode considerar ruídos no estado; e a solução é obtida para os instantes de amostragem das medidas. Diz-se ainda que o filtro de Kalman é a solução ótima de mínima variância, o que quer dizer que as equações do filtro de Kalman podem ser deduzidas a partir dessa premissa (Não tentem entender o artigo original sobre o filtro de Kalman. O autor, Kalman, é genial porém nada didático, pelo menos nesse artigo). O filtro de Kalman consiste de 2 etapas:

- Propagação ou predição ("time-update")
- Atualização ou correção ("measurement-update")

A fase de propagação, propaga o estado e a covariância do instante t_{k-1} a t_k . A fase de atualização corrige o estado e a covariância para o instante t_k devido à medida $\mathbf{y}_{t_k}$. O método tem portanto natureza recursiva e não necessita armazenar as medidas previamente em grandes matrizes.

3.4.1 Fase de propagação (predição)

Esta fase só é utilizada para, através do modelo dinâmico dado pela Equação 3.1, propagar o estado e a covariância entre instantes discretos. Aquí, a fim de simplificar a notação, os índices temporais serão também simplificados para $t_k \equiv k$. Agora, o risco de confusão pode aumentar se o texto não for lido corretamente. Somente o uso continuado irá fixar a correta utilização do filtro de Kalman. As equações formais são as seguintes:

$$\begin{aligned}\bar{\mathbf{x}}_k &= \boldsymbol{\varphi}_{k,k-1} \hat{\mathbf{x}}_{k-1} \\ \bar{\mathbf{P}}_k &= \boldsymbol{\varphi}_{k,k-1} \hat{\mathbf{P}}_{k-1} \boldsymbol{\varphi}_{k,k-1}^t + \boldsymbol{\Gamma}_k \mathbf{Q}_k \boldsymbol{\Gamma}_k^t\end{aligned}\quad (3.19)$$

onde $\bar{\mathbf{x}}_k$ e $\bar{\mathbf{P}}_k$ representam o estado e a covariância propagada para o instante k .

3.4.2 Fase de atualização (correção)

Esta fase só é utilizada para corrigir o estado e a covariância do instante k devido à medida y_k , através do modelo de observações dado pela Equação 3.4. Em essência, a(s) medida(s) do instante k fornece(m) informação para corrigir o estado e a covariância. Esta fase simplesmente incorpora essa informação às estimativas. O equacionamento é exatamente a forma de Kalman, ressalvadas as diferenças de notação devido aos índices temporais:

$$\begin{aligned}\mathbf{K}_k &= \bar{\mathbf{P}}_k \mathbf{H}_k^t (\mathbf{H}_k \bar{\mathbf{P}}_k \mathbf{H}_k^t + \mathbf{R}_k)^{-1} \\ \hat{\mathbf{P}}_k &= (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\mathbf{P}}_k \\ \hat{\mathbf{x}}_k &= \bar{\mathbf{x}}_k + \mathbf{K}_k (y_k - \mathbf{H}_k \bar{\mathbf{x}}_k)\end{aligned}\quad (3.20)$$

onde $\mathbf{K}_k$ é o "famoso" ganho de Kalman, e $\hat{\mathbf{x}}_k$ e $\hat{\mathbf{P}}_k$ são o estado e a covariância atualizada para o instante k respectivamente.

O algoritmo de Kalman resume-se a propagar o estado e covariância (calcular as variáveis com barra superior) e atualizá-las (calcular as variáveis com circunflexo). A Figura 3.1 mostra o diagrama temporal do algoritmo.




Fig. 3.1 - Diagrama temporal do filtro

3.4.3 Caso contínuo-discreto (discretização)

Na prática, é comum encontrar-se problemas cuja dinâmica é contínua no tempo. O caso de dinâmica discreta é mais raro, porém existe. Como aplicar o filtro de Kalman para dinâmica contínua? Deve-se realizar o que se chama comumente de discretização, ou então utilizar as fórmulas específicas para esse tipo de dinâmica. O caso contínuo-discreto acontece quando a dinâmica é contínua e as observações são discretas. Seja a dinâmica do estado dada por:

$$\dot{\mathbf{x}} = \mathbf{F}\mathbf{x} + \mathbf{G}\boldsymbol{\omega} \quad (3.21)$$

onde agora $\mathbf{x}$ é o estado continuamente variante no tempo, $\mathbf{F}$ é a matriz $n \times n$ que relaciona o estado e sua derivada linearmente, $\mathbf{G}$ é uma matriz $n \times p$ de adição do ruído dinâmico, e $\boldsymbol{\omega}$ é o ruído dinâmico contínuo. Este ruído é modelado por um processo branco descrito por:

$$\begin{aligned} E[\boldsymbol{\omega}] &= 0 \\ E[\boldsymbol{\omega}(t) \boldsymbol{\omega}^t(\tau)] &= \mathbf{Q}(t) \delta(t - \tau) \end{aligned} \quad (3.22)$$

onde $\mathbf{Q}(t)$ é a covariância do processo branco (ou um nome mais pomposo tal como densidade espectral de potência), e $\delta(t - \tau)$ é o delta de Dirac que vale 1 quando $t = \tau$, e 0 do contrário. Ou seja, o ruído branco é uma simplificação para um pulso instantâneo naquele instante. Também pode-se representá-lo por:

$$\boldsymbol{\omega} = N(\boldsymbol{\theta}, \mathbf{Q}(t)) \quad (3.23)$$

Neste caso contínuo-discreto, a única mudança no filtro de Kalman se dá na fase de propagação, que fica com o seguinte equacionamento:

- Propagação do estado:

$$\dot{\bar{\mathbf{x}}} = \mathbf{F} \bar{\mathbf{x}} \quad (3.24)$$

com condição inicial $\bar{\mathbf{x}}_{k-1} = \hat{\mathbf{x}}_{k-1}$.

- Propagação da covariância. Existem aqui duas alternativas equivalentes:

- Propagação contínua:

$$\dot{\bar{\mathbf{P}}} = \mathbf{F} \bar{\mathbf{P}} + \bar{\mathbf{P}} \mathbf{F}^t + \mathbf{G} \mathbf{Q} \mathbf{G}^t \quad (3.25)$$

com condição inicial $\bar{\mathbf{P}}_{k-1} = \hat{\mathbf{P}}_{k-1}$. Essa equação é chamada vulgarmente de equação de Riccati contínua.

- Propagação discreta:

$$\bar{P}_k = \varphi_{k,k-1} \hat{P}_{k-1} \varphi_{k,k-1}^t + \Gamma_k Q_k \Gamma_k^t \quad (3.26)$$

onde o termo $\Gamma_k Q_k \Gamma_k^t$ deve ser calculado por:

$$\Gamma_k Q_k \Gamma_k^t = \int_{k-1}^k \varphi_{\tau,k-1} G(\tau) Q(\tau) G^t(\tau) \varphi_{\tau,k-1}^t d\tau \quad (3.27)$$

e onde φ é a matriz de transição correspondente à dinâmica contínua. Em outras palavras, $\varphi_{k,k-1}$ é tal que:

$$\dot{\varphi} = F\varphi \quad (3.28)$$

com condição inicial $\varphi_{k-1,k-1} = I$, matriz identidade.

3.4.4 Sobre a matriz de transição

Cabe aqui relembrar algumas características da matriz de transição. Dada a equação dinâmica:

$$\dot{x} = Fx$$

prova-se, sob determinadas condições que existe a matriz de transição φ tal que:

$$x_{k+1} = \varphi_{k+1,k} x_k = e^{F\Delta t} x_k \quad (3.29)$$

lembrando que $e^{F\Delta t}$ é simplesmente a exponencial de uma matriz! Entretanto uma fórmula aproximada muito utilizada na prática é a seguinte expansão em série:

$$\varphi_{k+1,k} = e^{F(t_k - t_{k-1})} \cong I + F\Delta t + \frac{1}{2!} F^2 \Delta t^2 + \dots \quad (3.30)$$

que pode ser válida se o intervalo Δt é suficientemente pequeno.

3.5 Exemplo de aplicação 2

Apresenta-se aqui um exemplo de aplicação para fixar idéias e ilustrar o funcionamento dos métodos. Seja um sistema dinâmico (dinâmica e observações) dado por:

$$\dot{x} = x + \omega$$

$$y_k = 2x_k + v_k$$

com condição inicial $\bar{x}_0 = 1.5$ e $\bar{p}_0 = 1$, e cujas estatísticas são:

$$\omega = N(0, q) = N(0, 0.01)$$

$$v_k = N(0, r_k) = N(0, 0.01)$$

Suponha que as medidas constantes da Tabela 3.1 foram realizadas. A tabela mostra também os valores do estado verdadeiro nos respectivos instantes.

Tabela 3.1
Dados para o exemplo de aplicação 2

número	tempo	medida	estado exato
1	0	2.10	1.000
2	1	5.44	2.718
3	2	14.77	7.389

3.5.1 Solução pelo filtro de Kalman

Trata-se de um problema do tipo contínuo-discreto, isto é, dinâmica contínua e observações discretas. A fase de propagação consiste em integrar o estado e a covariância através das Equações 3.24 e 3.25. A solução para a equação do estado $\dot{x} = x$ é da forma:

$$\bar{x} = C_1 e^{\Delta t}$$

onde Δt é o intervalo de tempo; e a solução para a equação de Riccati da covariância $\dot{\bar{p}} = 2\bar{p} + 0.01$ é:

$$\bar{p} = C_2 e^{2\Delta t} - 0.005$$

As constantes de integração C_1 e C_2 devem ser recalculadas a cada passo, pois as condições iniciais variam. A fase de atualização fica com as seguintes equações:

$$K = 2\bar{p} / (4\bar{p} + 0.01)$$

$$\hat{x} = \bar{x} + K(y - 2\bar{x})$$

$$\hat{p} = (1 - 2K)\bar{p}$$

Com estas equações chegam-se aos resultados expressos na Tabela 3.2.

Tabela 3.2
Resultados do exemplo de aplicação 2 para o filtro de Kalman

t	$\bar{x}$	$\bar{p}$	K	$y - H\hat{x}$	$\hat{x}$	$\hat{p}$
0	1.5000	1.0000	0.4988	-0.9000	1.0511	0.0025
1	2.8572	0.0504	0.4764	-0.2745	2.7265	0.0024
2	7.4114	0.0495	0.4760	-0.0527	7.3863	0.0024

Os cálculos iniciais da primeira atualização e propagação estão mostrados em seguida:

- Atualização devido à medida no instante 0:

$$K_o = 2 / 4.01 = 0.4988$$

$$y - 2\bar{x} = 2.1 - 3 = -0.9$$

$$\hat{x} = 1.5 + 0.4988(-0.9) = 1.0511$$

$$\hat{p} = (1 - 2 \cdot 0.4988) \cdot 1$$

- Propagação para o instante 1:

$$\hat{x}(0) = C_1 e^0$$

$$C_1 = \hat{x}(0) = 1.0511$$

$$\bar{x}_1 = C_1 e^{\Delta t} = 1.0511 e^1 = 2.8572$$

$$\hat{p}(0) = C_2 e^{0-0.005}$$

$$C_2 = 0.0075$$

$$\bar{p}(1) = 0.0075 e^{2-0.005} = 0.0504$$

3.5.2 Solução por mínimos quadrados

Supondo que deseja-se a solução no instante 0 (época), acha-se inicialmente a equação dinâmica discreta. Como $\dot{x} = x$, têm-se imediatamente que:

$$x_k = e^{t_k - t_{k-1}} x_{k-1}$$

donde se deduz que a matriz de transição (no caso do exemplo é um valor escalar) é:

$$\phi_{k,k-1} = e^{t_k - t_{k-1}}$$

Para o problema em questão as matrizes $\mathbf{H}$ e $\mathbf{R}$ valem:

$$\mathbf{H} = \begin{bmatrix} H_0 \\ H_1 \phi_{1,0} \\ H_2 \phi_{2,0} \end{bmatrix} = \begin{bmatrix} 2 \\ 2e^{1-0} \\ 2e^{2-0} \end{bmatrix}$$

$$\mathbf{R} = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 0.001 \end{bmatrix}$$

Lembrando novamente as equações para processamento em lotes do estado e da matriz de covariância:

$$\hat{\mathbf{P}}_{t_o} = \left(\bar{\mathbf{P}}_{t_o}^{-1} + \mathbf{H}^t \mathbf{R}^{-1} \mathbf{H} \right)^{-1}$$

$$\hat{\mathbf{x}} = \hat{\mathbf{P}}_{t_o} \left(\bar{\mathbf{P}}_{t_o}^{-1} \bar{\mathbf{x}}_{t_o} + \mathbf{H}^t \mathbf{R}^{-1} \mathbf{y} \right)$$

vêm:

$$\hat{p}_o = \left(1^{-1} + \begin{bmatrix} 2 & 2e & 2e^2 \end{bmatrix} \begin{bmatrix} 100 & 0 & 0 \\ 0 & 100 & 0 \\ 0 & 0 & 100 \end{bmatrix} \begin{bmatrix} 2 \\ 2e \\ 2e^2 \end{bmatrix} \right)^{-1} = 1/25196$$

$$\hat{x}_o = \hat{p}_o \left(1^{-1} \cdot 1.5 + 200 \begin{bmatrix} 1 & e & e^2 \end{bmatrix} \begin{bmatrix} 2.1 \\ 5.44 \\ 14.77 \end{bmatrix} \right) = 25206 \hat{p}_o$$

Portanto a solução final vale:

$$\hat{x}_o = 1.0004$$

$$\hat{p}_o = 0.000039689$$

ou seja $\hat{x}_o = 1.0004 \pm 0.0063$.

Agora, como comparar os resultados entre o método de mínimos quadrados e o filtro de Kalman? Como o filtro de Kalman fornece estimativas somente nos instantes de amostragem, deve-se propagar a estimativa e covariância da solução de mínimos quadrados para estes instantes. Lembrando que o mínimos quadrados não considera ruído dinâmico, as equações de propagação são:

$$\hat{x}_k = \phi_{k,o} \hat{x}_o$$

$$\hat{p}_k = \phi_{k,o} \hat{p}_o \phi_{k,o}^t$$

Daí, segue-se que:

$$\hat{x}_1 = e^1 \hat{x}_0 = 2.7194$$

$$\hat{p}_1 = e^1 \hat{p}_0 e^1 = .00029326$$

$$\hat{x}_2 = e^2 \hat{x}_0 = 7.3921$$

$$\hat{p}_2 = e^2 \hat{p}_0 e^2 = .0022$$

A Tabela 3.3 mostra a diferença de resultados entre o filtro de Kalman e mínimos quadrados.

Tabela 3.3
Comparação de resultados do exemplo de aplicação 2

t	x	$\hat{x} \pm \sigma$	$\hat{x} \pm \sigma$
	Exato	Filtro de Kalman	Mínimos Quadrados
0	1.000	1.0511±0.050	1.0004±0.0063
1	2.718 = e	2.7265±0.049	2.7194±0.0171
2	7.389 = e^2	7.3863±0.049	7.3921±0.0466

Observar que poder-se-ia obter a solução de mínimos quadrados para outra época, por exemplo, $t=2$, e então comparar os resultados para os outros instantes da mesma forma. Em geral, o mínimos quadrados tende a minimizar os resíduos pela média, ao passo que o filtro de Kalman responde instantaneamente à medida. Para aplicações "off-line" (não de tempo real) o mínimos quadrados é mais utilizado, ao passo que para aplicações de tempo real ou quase real a escolha recai no filtro de Kalman.

3.6 Exercícios

1) Considere o exemplo de aplicação 2 da Seção 3.5.

a) Refaça o filtro de Kalman, viz. Tabela 3.2, considerando o ruído dinâmico com:

$$\omega = N(0, q) = N(0, 0.000001)$$

O que você nota de diferente?

b) Da mesma forma, refaça o filtro de Kalman, considerando que o ruído de medida seja:

$$v_k = N(0, r_k) = N(0, 0.000001)$$

Você teria alguma conclusão a tirar?

c) Compare os resultados dos itens b e c com o resultado de mínimos quadrados da Tabela 3.3. O que você poderia dizer?

2) Prove que a equação de Riccati contínua é equivalente à discreta, ou seja:

$$\dot{\bar{P}} = F\bar{P} + \bar{P}F^t + GQG^t$$

é equivalente a:

$$\bar{P}_k = \phi_{k,k-1} \hat{P}_{k-1} \phi_{k,k-1}^t + \Gamma_k Q_k \Gamma_k^t$$

com

$$\Gamma_k Q_k \Gamma_k^t = \int_{k-1}^k \phi_{\tau,k-1} G(\tau) Q(\tau) G^t(\tau) \phi_{\tau,k-1}^t d\tau$$

4. ESTIMAÇÃO NÃO-LINEAR DE ESTADOS

Agora, iremos à parte mais complexa da teoria de estimação. Este é o caso mais genérico no sentido de que iremos estimar estados que variam não-linearmente, e as medidas são também relacionadas não-linearmente ao estado.

4.1 Linearização da dinâmica contínua

Suponha que se tenha uma dinâmica contínua não-linear. Em outras palavras, o estado varia contínua e não-linearmente com o tempo. Como só existem teorias para estimadores lineares, é necessário realizar o que se chama de linearização. Este passo nada mais é do que a expansão de Taylor truncada no termo linear. Seja então a dinâmica não-linear:

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, t) + \mathbf{G}\boldsymbol{\omega} \quad (4.1)$$

onde $\boldsymbol{\omega}$ é o já conhecido processo branco que modela o ruído dinâmico, com estatísticas dadas por $\boldsymbol{\omega} = N(\boldsymbol{\theta}, \mathbf{Q})$ e $\mathbf{f}$ a função vetorial não-linear do estado $\mathbf{x}$ e do tempo t . Expandindo $\mathbf{f}$ em série de Taylor vem:

$$\mathbf{f} = \mathbf{f}(\bar{\mathbf{x}}, t) + \left[\frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{\mathbf{x}=\bar{\mathbf{x}}} (\mathbf{x} - \bar{\mathbf{x}}) + \mathcal{O}(2) \quad (4.2)$$

Definindo-se os seguintes desvios:

$$\begin{aligned} \delta \mathbf{x} &\equiv \mathbf{x} - \bar{\mathbf{x}} \\ \delta \dot{\mathbf{x}} &\equiv \dot{\mathbf{x}} - \dot{\bar{\mathbf{x}}} = \dot{\mathbf{x}} - \mathbf{f}(\bar{\mathbf{x}}, t) \end{aligned} \quad (4.3)$$

chega-se finalmente à expressão linearizada:

$$\delta \dot{\mathbf{x}} = \left[\frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{\mathbf{x}=\bar{\mathbf{x}}} \delta \mathbf{x} + \mathbf{G}\boldsymbol{\omega} \quad (4.4)$$

Definindo-se

$$\mathbf{F} \equiv \left[\frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{\mathbf{x}=\bar{\mathbf{x}}} \quad (4.5)$$

têm-se:

$$\delta \dot{\mathbf{x}} = \mathbf{F} \delta \mathbf{x} + \mathbf{G}\boldsymbol{\omega} \quad (4.6)$$

que é a linearização da Equação original 4.1. Naturalmente esta linearização é válida enquanto o $\delta \mathbf{x}$ for pequeno. Este é um dos problemas das linearizações: deve-se gerar uma

trajetória de referência $\bar{x}$ suficientemente próxima à trajetória verdadeira para que os estimadores convirjam!!! Agora, o vetor de estado a ser estimado são desvios em relação a alguma solução de referência.

4.2 Linearização das medidas discretas

As medidas também podem em geral vir na forma não-linear:

$$y_k = h_k(x_k) + v_k \quad (4.7)$$

onde v é a sequência branca definida por $v_k = N(0, R_k)$, e h é uma função vetorial não-linear do estado. O procedimento de linearização é similar ao caso de linearização da dinâmica. Expande-se h em série de Taylor em torno de uma referência:

$$y_k = h_k(\bar{x}_k) + \left[\frac{\partial h_k}{\partial x} \right]_{x=\bar{x}_k} (x - \bar{x}_k) + O(2) + v_k \quad (4.8)$$

e, definindo-se:

$$\delta y_k \equiv y_k - h_k(\bar{x}_k) \quad (4.9)$$

$$H_k \equiv \left[\frac{\partial h_k}{\partial x} \right]_{x=\bar{x}_k}$$

a equação linearizada de medidas torna-se:

$$\delta y_k = H_k \delta x_k + v_k \quad (4.10)$$

Logo, a equação de medidas torna-se também uma equação que relaciona desvios das medidas calculadas δy_k em relação a alguma trajetória de referência, e mantém uma relação linear com os desvios do estado δx_k .

4.3 Discretização da dinâmica contínua não-linear

A dinâmica de estado está na forma contínua. Pode-se discretizá-la da forma que se segue. Seja a dinâmica não-linear contínua:

$$\delta \dot{x} = F \delta x + G \omega \quad (4.11)$$

Então, a discretização fará esta equação ficar na forma:

$$\delta x_k = \Phi_{k,k-1} \delta x_{k-1} + \Gamma_k \omega_k \quad (4.12)$$

onde $\boldsymbol{\varphi}_{k,k-1}$ é agora a matriz de transição que relaciona os desvios $\delta \mathbf{x}$ entre os instantes t_k e t_{k-1} , sendo calculada por integração através de:

$$\dot{\boldsymbol{\varphi}} = \mathbf{F}\boldsymbol{\varphi} \quad (4.13)$$

com condição inicial $\boldsymbol{\varphi}_{k-1,k-1} = \mathbf{I}$. Lembrar que:

$$\boldsymbol{\varphi} = e^{\mathbf{F}\Delta t} \cong \mathbf{I} + \mathbf{F}\Delta t + \frac{1}{2!}\mathbf{F}^2\Delta t^2 + \dots \quad (4.14)$$

4.4 Mínimos quadrados não-linear

O estimador não-linear de mínimos quadrados assume o seguinte sistema dinâmico contínuo-discreto:

$$\begin{aligned} \dot{\mathbf{x}} &= \mathbf{f}(\mathbf{x}) \\ \mathbf{y}_k &= \mathbf{h}_k(\mathbf{x}_k) + \mathbf{v}_k \end{aligned} \quad (4.15)$$

onde $\mathbf{v} = N(\mathbf{0}, \mathbf{R})$. Lembrar também que o mínimos quadrados assume dinâmica de estado exata, sem ruído. Sejam as informações a priori dadas por $\hat{\mathbf{x}}_o = \hat{\mathbf{x}}_o(t_o)$ e $\mathbf{P}_o = \hat{\mathbf{P}}_o(t_o)$, na época t_o onde se deseja as estimativas. Por simplicidade de notação deixamos a notação temporal de lado, assumindo implicitamente a época t_o , e o índice representando o número da iteração. No caso não-linear, o mínimos quadrados tem natureza iterativa, onde se refina os desvios ao invés do estado. Definindo-se os seguintes desvios:

$$\begin{aligned} \delta \bar{\mathbf{x}}_i &\equiv \hat{\mathbf{x}}_i - \hat{\mathbf{x}}_o \\ \delta \hat{\mathbf{x}}_i &\equiv \hat{\mathbf{x}}_i - \hat{\mathbf{x}}_{i-1} \end{aligned} \quad (4.16)$$

As equações seguintes implementam o algoritmo:

- Cálculo da covariância:

$$\hat{\mathbf{P}}_i = \left(\hat{\mathbf{P}}_o^{-1} + \mathbf{H}' \mathbf{R}^{-1} \mathbf{H} \right)^{-1} \quad (4.17)$$

- Cálculo do desvio no estado:

$$\delta \hat{\mathbf{x}}_i = \hat{\mathbf{P}}_i \left(\bar{\mathbf{P}}_o^{-1} \delta \bar{\mathbf{x}}_{i-1} + \mathbf{H}' \mathbf{R}^{-1} \delta \mathbf{y} \right) \quad (4.18)$$

onde:

$$\mathbf{H} = \begin{bmatrix} \mathbf{H}_1 \\ \mathbf{H}_2 \\ \vdots \end{bmatrix} = \begin{bmatrix} \mathbf{H}_{t_1} \boldsymbol{\varphi}_{t_1, t_o} \\ \mathbf{H}_{t_2} \boldsymbol{\varphi}_{t_2, t_o} \\ \vdots \end{bmatrix} \quad (4.19)$$

$$\delta \mathbf{y} = \begin{bmatrix} y_{t_1} - h_{t_1}(\hat{\mathbf{x}}_{t_1}) \\ y_{t_2} - h_{t_2}(\hat{\mathbf{x}}_{t_2}) \\ \vdots \end{bmatrix}$$

com

$\mathbf{H}_{t_k} = [\partial \mathbf{h}_{t_k} / \partial \mathbf{x}]_{\mathbf{x}=\mathbf{x}_{t_k}}$ e $\mathbf{x}_{t_k}$ obtido através da integração da equação diferencial da Equação 4.15. Normalmente as iterações prosseguem até se atingir a convergência. Basicamente, o critério mais utilizado para finalizar o algoritmo consiste em se verificar quando o desvio $\delta \mathbf{x}_i$ se torna suficientemente pequeno. A solução para o estado será então:

$$\hat{\mathbf{x}}_i = \hat{\mathbf{x}}_{i-1} + \delta \hat{\mathbf{x}}_i \quad (4.20)$$

com covariância correspondente $\hat{\mathbf{P}}_i$.

4.5 Filtro linearizado e estendido de Kalman

No caso dos filtros de Kalman aplicado a sistemas não-lineares, assume-se o seguinte sistema contínuo-discreto:

$$\begin{aligned} \dot{\mathbf{x}} &= \mathbf{f}(\mathbf{x}) + \mathbf{G}\boldsymbol{\omega} \\ \mathbf{y}_k &= \mathbf{h}_k(\mathbf{x}_k) + \mathbf{v}_k \end{aligned} \quad (4.21)$$

onde $\boldsymbol{\omega} = N(\mathbf{0}, \mathbf{Q})$ e $\mathbf{v} = N(\mathbf{0}, \mathbf{R})$. Dentre as mais utilizadas, estão duas variantes do filtro de Kalman, a saber: filtro linearizado e filtro estendido. Ambas são essencialmente abordagens diferentes de se utilizar as equações lineares do filtro de Kalman.

O filtro linearizado gera uma trajetória de referência válida do início ao fim do processo de estimação, e as linearizações são sempre em torno dessa referência.

Já o filtro estendido gera trajetórias de referência que são atualizadas a cada processamento das medidas do instante correspondente.

A pergunta é: qual delas escolher? Normalmente, se o modelo da dinâmica de estado é bastante preciso, pode-se usar o filtro linearizado, desde que a informação a priori (chute inicial) seja próxima dos valores verdadeiros, de modo que as linearizações sejam válidas. Caso contrário, se o modelo é impreciso, simplificado, é preferível o filtro estendido, que converge atualizando sempre a trajetória de referência. A vantagem computacional do filtro

linearizado consiste em se poder calcular as covariâncias e ganhos "off-line", deixando a carga de CPU livre para processamento somente das medidas. Esta vantagem pode ser importante em sistemas de tempo real, onde qualquer economia de CPU é importante.

A Figura 4.1 mostra o diagrama temporal do filtro linearizado, e a Figura 4.2 faz o mesmo com relação ao filtro estendido.




Fig. 4.1 - Diagrama temporal do filtro linearizado de Kalman




Fig. 4.2 - Diagrama temporal do filtro estendido de Kalman

4.5.1 Filtro linearizado

O primeiro passo nesse algoritmo é a de gerar a trajetória de referência (nominal), genericamente denominada de $\mathbf{x}_n$, através de:

$$\dot{\mathbf{x}}_n = \mathbf{f}(\mathbf{x}_n) \quad (4.22)$$

com condição inicial dada por $\mathbf{x}_n(t_o) = \hat{\mathbf{x}}(t_o)$, onde $\hat{\mathbf{x}}(t_o)$ e $\hat{\mathbf{P}}(t_o)$ são a informação a priori (chute inicial).

As equações do filtro linearizado consistem em fases de propagação e de atualização, à semelhança do filtro linear de Kalman. As equações são as seguintes:

- Propagação do instante t_{k-1} a t_k :

$$\begin{aligned}\dot{\bar{\mathbf{x}}} &= \mathbf{f}(\mathbf{x}_n) + \mathbf{F}_{\mathbf{x}_n}(\bar{\mathbf{x}} - \mathbf{x}_n) \\ \dot{\bar{\mathbf{P}}} &= \mathbf{F}_{\mathbf{x}_n} \bar{\mathbf{P}} + \bar{\mathbf{P}} \mathbf{F}_{\mathbf{x}_n}^t + \mathbf{G} \mathbf{Q} \mathbf{G}^t\end{aligned}\quad (4.23)$$

com condições iniciais $\bar{\mathbf{x}}_{k-1} = \hat{\mathbf{x}}_{k-1}$ e $\bar{\mathbf{P}}_{k-1} = \hat{\mathbf{P}}_{k-1}$, e com: $\mathbf{F}_{\mathbf{x}_n} \equiv [\partial \mathbf{f} / \partial \mathbf{x}]_{\mathbf{x}=\mathbf{x}_n}$.

- Atualização no instante t_k :

$$\begin{aligned}\mathbf{K}_k &= \bar{\mathbf{P}}_k \mathbf{H}_k^t (\mathbf{H}_k \bar{\mathbf{P}}_k \mathbf{H}_k^t + \mathbf{R}_k)^{-1} \\ \hat{\mathbf{P}}_k &= (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\mathbf{P}}_k \\ \hat{\mathbf{x}}_k &= \bar{\mathbf{x}}_k + \mathbf{K}_k \{y_k - \mathbf{h}_k(\mathbf{x}_n(t_k)) - \mathbf{H}_k(\bar{\mathbf{x}}_k - \mathbf{x}_n(t_k))\}\end{aligned}\quad (4.24)$$

com $\mathbf{H}_k \equiv [\partial \mathbf{h}_k / \partial \mathbf{x}]_{\mathbf{x}=\mathbf{x}_n(t_k)}$. Notar pelas Equações 4.23 e 4.24 que $\bar{\mathbf{P}}$, $\mathbf{K}$ e $\hat{\mathbf{P}}$ podem ser calculados "off-line".

4.5.2 Filtro estendido

O filtro estendido atualiza sempre a trajetória de referência em torno da estimativa mais atual disponível. Consiste, analogamente, em fases de propagação e de atualização:

- Propagação de t_{k-1} a t_k :

- Do estado:

$$\dot{\bar{\mathbf{x}}} = \mathbf{f}(\bar{\mathbf{x}}) \text{ com condição inicial } \bar{\mathbf{x}}_{k-1} = \hat{\mathbf{x}}_{k-1} \quad (4.25)$$

- Da covariância: Existem 02 maneiras de se propagar a covariância:

- Propagação contínua:

$$\dot{\bar{\mathbf{P}}} = \mathbf{F} \bar{\mathbf{P}} + \bar{\mathbf{P}} \mathbf{F}^t + \mathbf{G} \mathbf{Q} \mathbf{G}^t \quad (4.26)$$

com condição inicial $\bar{\mathbf{P}}_{k-1} = \hat{\mathbf{P}}_{k-1}$.

- Propagação discreta:

$$\bar{\mathbf{P}}_k = \boldsymbol{\varphi}_{k,k-1} \hat{\mathbf{P}}_{k-1} \boldsymbol{\varphi}_{k,k-1}^t + \boldsymbol{\Gamma}_k \mathbf{Q}_k \boldsymbol{\Gamma}_k^t \quad (4.27)$$

onde $\boldsymbol{\varphi}_{k,k-1}$ é calculada através de

$$\dot{\boldsymbol{\varphi}} = \mathbf{F}\boldsymbol{\varphi} \quad (4.28)$$

com condição inicial $\boldsymbol{\varphi}_{k-1,k-1} = \mathbf{I}$ e onde $\mathbf{F} \equiv [\partial \mathbf{f} / \partial \mathbf{x}]_{\mathbf{x}=\bar{\mathbf{x}}}$. O termo $\boldsymbol{\Gamma}_k \mathbf{Q}_k \boldsymbol{\Gamma}_k^t$ é obtido via:

$$\boldsymbol{\Gamma}_k \mathbf{Q}_k \boldsymbol{\Gamma}_k^t = \int_{k-1}^k \boldsymbol{\varphi}_{\tau,k-1} \mathbf{G}(\tau) \mathbf{Q}(\tau) \mathbf{G}^t(\tau) \boldsymbol{\varphi}_{\tau,k-1}^t d\tau \quad (4.29)$$

- Atualização no instante t_k :

$$\begin{aligned} \mathbf{K}_k &= \bar{\mathbf{P}}_k \mathbf{H}_k^t (\mathbf{H}_k \bar{\mathbf{P}}_k \mathbf{H}_k^t + \mathbf{R}_k)^{-1} \\ \hat{\mathbf{P}}_k &= (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\mathbf{P}}_k \\ \hat{\mathbf{x}}_k &= \bar{\mathbf{x}}_k + \mathbf{K}_k [\mathbf{y}_k - \mathbf{h}_k(\bar{\mathbf{x}}_k)] \end{aligned} \quad (4.30)$$

com $\mathbf{H}_k \equiv [\partial \mathbf{h}_k / \partial \mathbf{x}]_{\mathbf{x}=\bar{\mathbf{x}}_k}$.

4.6 Exemplo de aplicação 3

Neste exemplo, exercitar-se-á o filtro estendido de Kalman que é de aplicação mais complexa. Seja o sistema dinâmico dado pelas seguintes equações:

$$\begin{aligned} \dot{x} &= -\sin x + \omega \\ y_k &= \frac{1}{2} \sin 2x_k + v_k \end{aligned}$$

com as seguintes estatísticas disponíveis:

$$\begin{aligned} x_o &= N(1.4, 0.01) \\ \omega &= N(0, q) = N(0, 0.01) \\ v_k &= N(0, r) = N(0, 0.0001) \end{aligned}$$

ou seja, informação a priori (chute inicial) dada por $\hat{x}_o = 1.4$ e $\hat{p}_o = 0.01$; covariância do ruído dinâmico dada por $q = 0.01$ e covariância do erro de medidas dada por $r = 0.0001$. A Tabela 4.1 contém as medidas coletadas, bem como o valor do estado verdadeiro.

Tabela 4.1
Exemplo de aplicação 3

tempo	medida	estado exato
0.0	-	1.5000
0.5	0.452	1.0286
1.0	0.474	0.6603
1.5	0.377	0.4099

As seguintes derivadas são necessárias:

$$F = \frac{\partial f}{\partial x} = \frac{\partial(-\sin x)}{\partial x} = -\cos x$$

$$H = \frac{\partial h}{\partial x} = \frac{\partial(\sin 2x / 2)}{\partial x} = \cos 2x$$

As equações genéricas para a fase de propagação são:

$$\dot{x} = -\sin x$$

$$\dot{p} = -2p \cos x + q = -2p \cos x + 0.01$$

que não tem solução analítica imediata. As equações para atualização são:

$$K_k = \bar{p}_k \cos 2\bar{x}_k / (\bar{p}_k \cos^2 2\bar{x}_k + 0.0001)$$

$$\hat{x}_k = \bar{x}_k + K_k (y_k - \sin 2\bar{x}_k / 2)$$

$$\hat{p}_k = (1 - K_k \cos 2\bar{x}_k) \bar{p}_k$$

Na sequência ilustrar-se-á o primeiro passo de atualização e propagação. Como a primeira medida ocorre no instante $t_1=0.5$, a informação a priori é considerada como sendo $\hat{x}_o = 1.4$ e $\hat{p}_o = 0.01$, e deve ser feita uma propagação até o instante $t_1=0.5$:

- propagação do estado de t_0 a t_1 via:

$$\dot{x} = -\sin x$$

com condição inicial $\hat{x}_o = 1.4$. A solução (calculada no computador) é $\bar{x}_1 = 0.9446174$.

- propagação da covariância de t_0 a t_1 via:

$$\dot{p} = -2p \cos x + 0.010$$

com condição inicial $\hat{p}_0 = 0.01$. A solução via computador é $\bar{p}_1 = 0.0107578$.

- ganho de Kalman para $t_1=0.5$:

$$K_1 = -2.9173714$$

- atualização do estado para $t_1=0.5$:

$$\hat{x}_1 = 1.0113165$$

- atualização da covariância para $t_1=0.5$:

$$\hat{p}_1 = 9.3181767 \times 10^{-4}$$

A Tabela 4.2 mostra os resultados finais passo a passo. A Tabela 4.3 mostra os desvios verdadeiros e respectivos desvios-padrão, onde x_v representa o estado verdadeiro e os σ são os desvios-padrão. Quanto mais afinado ("tunned") o filtro, melhor a covariância espelha o erro verdadeiro ocorrido. Nota-se neste exemplo que os σ -s são da ordem do erros reais ocorridos.

Tabela 4.2

Cálculos passo a passo para o filtro estendido no exemplo de aplicação 3

t	$\bar{x}$	$\bar{p}$	K	$y - h(\bar{x})$	$\hat{x}$	$\hat{p}$
0.0	-	-	-	-	1.4000	1.0000×10^{-2}
0.5	0.9446	1.0758×10^{-2}	-2.9174	-0.02286	1.0113	9.3182×10^{-4}
1.0	0.6480	4.0240×10^{-3}	2.7551	-0.00723	0.6280	1.0151×10^{-3}
1.5	0.3890	3.7234×10^{-3}	1.3332	0.02608	0.4238	1.8717×10^{-4}

Tabela 4.3

Desvios verdadeiros passo a passo para o filtro estendido

t	$x_v - \bar{x}$	$\sigma_{\bar{x}}$	$x_v - \hat{x}$	$\sigma_{\hat{x}}$
0.0	-	-	0.1000	0.1000
0.5	0.0840	0.1037	0.0173	0.0305
1.0	0.0123	0.0634	0.0323	0.0319
1.5	0.0209	0.0610	-0.0139	0.0137