

EE-254: Controle Preditivo

13 Setembro 2022

Considere um sistema com dinâmica a tempo discreto descrita por

$$x(k+1) = Ax(k) + Bu(k)$$

com entrada $u(k) \in \mathbb{R}^p$ e estado $x(k) \in \mathbb{R}^n$ sujeitos às seguintes restrições:

$$u(k) \in \mathcal{U}, \quad x(k) \in \mathcal{X}, \quad \forall k \geq 0$$

$$\mathcal{U} = \{ u \in \mathbb{R}^p : S_u u \leq b_u \}, \quad \mathcal{X} = \{ x \in \mathbb{R}^n : S_x x \leq b_x \}$$

Deseja-se conduzir o estado para um ponto de equilíbrio $\bar{x} \in \text{int}(\mathcal{X})$, associado a um valor de equilíbrio $\bar{u} \in \text{int}(\mathcal{U})$.

Suponha que, sob a ação de uma dada lei de controle estabilizante da forma

$$u(k) = -K[x(k) - \bar{x}] + \bar{u} \quad (\star)$$

o máximo conjunto admissível quanto às restrições de estado e controle seja descrito por

$$\mathcal{X}_f = \{ x \in \mathbb{R}^n : S_f x \leq b_f \}$$

Suponha que, sob a ação de uma dada lei de controle estabilizante da forma

$$u(k) = -K[x(k) - \bar{x}] + \bar{u} \quad (\star)$$

o máximo conjunto admissível quanto às restrições de estado e controle seja descrito por

$$\mathcal{X}_f = \{ x \in \mathbb{R}^n : S_f x \leq b_f \}$$

Se o estado inicial $x(0)$ estiver em $\mathcal{X}_f$, a lei de controle $(\star)$ poderá ser aplicada a partir de $k = 0$ e o estado será conduzido ao ponto de equilíbrio desejado, sem que as restrições sejam violadas.

Suponha que, sob a ação de uma dada lei de controle estabilizante da forma

$$u(k) = -K[x(k) - \bar{x}] + \bar{u} \quad (\star)$$

o máximo conjunto admissível quanto às restrições de estado e controle seja descrito por

$$\mathcal{X}_f = \{ x \in \mathbb{R}^n : S_f x \leq b_f \}$$

Se o estado inicial $x(0)$ estiver em $\mathcal{X}_f$, a lei de controle $(\star)$ poderá ser aplicada a partir de $k = 0$ e o estado será conduzido ao ponto de equilíbrio desejado, sem que as restrições sejam violadas.

O que fazer se $x(0) \notin \mathcal{X}_f$?

- Condução do estado a um conjunto alvo $\mathcal{X}_f$
- Custo terminal e custo de trajetória
- Expressão do custo e das restrições empregando notação mais concisa
- Formulação do problema de otimização na forma de **programação quadrática**
- Programação quadrática: Existência de solução ótima. Convexidade.
- Solução de problemas de programação quadrática no Matlab

Condução do estado ao conjunto $\mathcal{X}_f$

Dado um estado inicial $x(0) \notin \mathcal{X}_f$,
gostaríamos de obter uma sequência
de N ações de controle

$$u(0) \in \mathcal{U}$$

$$u(1) \in \mathcal{U}$$

$$\vdots$$

$$u(N-1) \in \mathcal{U}$$

Condução do estado ao conjunto $\mathcal{X}_f$

Dado um estado inicial $x(0) \notin \mathcal{X}_f$,
gostaríamos de obter uma sequência
de N ações de controle

de modo que

$$u(0) \in \mathcal{U}$$

$$x(1) \in \mathcal{X}$$

$$u(1) \in \mathcal{U}$$

$$x(2) \in \mathcal{X}$$

$$\vdots$$

$$\vdots$$

$$u(N-1) \in \mathcal{U}$$

$$x(N-1) \in \mathcal{X}$$

$$x(N) \in \mathcal{X}_f$$

Custo terminal e custo de trajetória

De maneira geral, a solução (se existir) não será única.

Custo terminal e custo de trajetória

De maneira geral, a solução (se existir) não será única. Portanto, é necessário adotar um critério que permita escolher a melhor sequência de ações de controle para realizar a tarefa.

Custo terminal e custo de trajetória

De maneira geral, a solução (se existir) não será única. Portanto, é necessário adotar um critério que permita escolher a melhor sequência de ações de controle para realizar a tarefa.

Para isso, empregaremos um custo da forma

$$J = \|x(N) - \bar{x}\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k) - \bar{x}\|_Q^2 + \|u(k) - \bar{u}\|_R^2 \right]$$

sendo P_f, Q, R matrizes de peso simétricas e positivo-definidas.

Custo terminal e custo de trajetória

De maneira geral, a solução (se existir) não será única. Portanto, é necessário adotar um critério que permita escolher a melhor sequência de ações de controle para realizar a tarefa.

Para isso, empregaremos um custo da forma

$$J = \|x(N) - \bar{x}\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k) - \bar{x}\|_Q^2 + \|u(k) - \bar{u}\|_R^2 \right]$$

sendo P_f, Q, R matrizes de peso simétricas e positivo-definidas.

A expressão de J envolve uma parcela de **custo terminal** e outra de **custo de trajetória**.

Custo terminal e custo de trajetória

De maneira geral, a solução (se existir) não será única. Portanto, é necessário adotar um critério que permita escolher a melhor sequência de ações de controle para realizar a tarefa.

Para isso, empregaremos um custo da forma

$$J = \|x(N) - \bar{x}\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k) - \bar{x}\|_Q^2 + \|u(k) - \bar{u}\|_R^2 \right]$$

sendo P_f, Q, R matrizes de peso simétricas e positivo-definidas.

A expressão de J envolve uma parcela de **custo terminal** e outra de **custo de trajetória**.

Consideremos inicialmente $\bar{x} = 0$ e $\bar{u} = 0$.

$$J = \|x(N)\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k)\|_Q^2 + \|u(k)\|_R^2 \right]$$

$$J = \|x(N)\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k)\|_Q^2 + \|u(k)\|_R^2 \right]$$

A expressão para o custo pode ser reescrita empregando a seguinte notação:

$$\mathbf{u} = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \in \mathbb{R}^{pN}, \quad \mathbf{x} = \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \in \mathbb{R}^{nN}$$

$$J = \|x(N)\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k)\|_Q^2 + \|u(k)\|_R^2 \right]$$

A expressão para o custo pode ser reescrita empregando a seguinte notação:

$$\mathbf{u} = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \in \mathbb{R}^{pN}, \quad \mathbf{x} = \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \in \mathbb{R}^{nN}$$

lembrando que o estado inicial $x(0)$ foi fixado na formulação do problema.

Com isso, a somatória

$$\sum_{k=0}^{N-1} \|u(k)\|_R^2 = u^T(0)Ru(0) + u^T(1)Ru(1) + \cdots + u^T(N-1)Ru(N-1)$$

Com isso, a somatória

$$\sum_{k=0}^{N-1} \|u(k)\|_R^2 = u^T(0)Ru(0) + u^T(1)Ru(1) + \cdots + u^T(N-1)Ru(N-1)$$

fica na forma

$$\underbrace{\begin{bmatrix} u^T(0) & u^T(1) & \cdots & u^T(N-1) \end{bmatrix}}_{\mathbf{u}^T} \begin{bmatrix} R & 0 & \cdots & 0 \\ 0 & R & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R \end{bmatrix} \underbrace{\begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix}}_{\mathbf{u}}$$

Com isso, a somatória

$$\sum_{k=0}^{N-1} \|u(k)\|_R^2 = u^T(0)Ru(0) + u^T(1)Ru(1) + \cdots + u^T(N-1)Ru(N-1)$$

fica na forma

$$\underbrace{\begin{bmatrix} u^T(0) & u^T(1) & \cdots & u^T(N-1) \end{bmatrix}}_{\mathbf{u}^T} \begin{bmatrix} R & 0 & \cdots & 0 \\ 0 & R & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R \end{bmatrix} \underbrace{\begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix}}_{\mathbf{u}}$$

tendo-se omitido a dimensão $(p \times p)$ das submatrizes de zeros, por brevidade.

Convencionando ainda a notação

$$\mathbf{R} = \begin{bmatrix} R & 0 & \cdots & 0 \\ 0 & R & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R \end{bmatrix} \in \mathbb{R}^{pN \times pN}$$

ou, de forma abreviada:

$$\mathbf{R} = \text{diag}_N(R)$$

Convencionando ainda a notação

$$\mathbf{R} = \begin{bmatrix} R & 0 & \cdots & 0 \\ 0 & R & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R \end{bmatrix} \in \mathbb{R}^{pN \times pN}$$

ou, de forma abreviada:

$$\mathbf{R} = \text{diag}_N(R)$$

pode-se escrever

$$\sum_{k=0}^{N-1} \|u(k)\|_R^2 = \|\mathbf{u}\|_{\mathbf{R}}^2$$

De forma similar, pode-se escrever

$$\begin{aligned} \|x(N)\|_{P_f}^2 + \sum_{k=0}^{N-1} \|x(k)\|_Q^2 &= x^T(0)Qx(0) \\ &+ x^T(1)Qx(1) + \cdots + x^T(N-1)Qx(N-1) + x^T(N)P_fx(N) \end{aligned}$$

De forma similar, pode-se escrever

$$\begin{aligned}
 \|x(N)\|_{P_f}^2 + \sum_{k=0}^{N-1} \|x(k)\|_Q^2 &= x^T(0)Qx(0) \\
 &+ x^T(1)Qx(1) + \cdots + x^T(N-1)Qx(N-1) + x^T(N)P_fx(N) \\
 &= x^T(0)Qx(0) + \\
 &\underbrace{\begin{bmatrix} x^T(1) & x^T(2) & \cdots & x^T(N) \end{bmatrix}}_{x^T} \begin{bmatrix} Q & 0 & \cdots & 0 \\ 0 & Q & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & P_f \end{bmatrix} \underbrace{\begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix}}_x
 \end{aligned}$$

Adotando a notação

$$\mathbf{Q} = \begin{bmatrix} Q & 0 & \cdots & 0 \\ 0 & Q & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & P_f \end{bmatrix} \in \mathbb{R}^{nN \times nN}$$

ou, de forma abreviada:

$$\mathbf{Q} = \begin{bmatrix} \text{diag}_{N-1}(Q) & 0 \\ 0 & P_f \end{bmatrix}$$

Adotando a notação

$$\mathbf{Q} = \begin{bmatrix} Q & 0 & \cdots & 0 \\ 0 & Q & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & P_f \end{bmatrix} \in \mathbb{R}^{nN \times nN}$$

ou, de forma abreviada:

$$\mathbf{Q} = \begin{bmatrix} \text{diag}_{N-1}(Q) & 0 \\ 0 & P_f \end{bmatrix}$$

pode-se escrever

$$\|x(N)\|_{P_f}^2 + \sum_{k=0}^{N-1} \|x(k)\|_Q^2 = \|x(0)\|_Q^2 + \|\mathbf{x}\|_{\mathbf{Q}}^2$$

Em resumo, o custo pode ser reescrito como

$$J(\mathbf{x}, \mathbf{u}) = \|\mathbf{x}(0)\|_Q^2 + \|\mathbf{x}\|_Q^2 + \|\mathbf{u}\|_R^2$$

Em resumo, o custo pode ser reescrito como

$$J(\mathbf{x}, \mathbf{u}) = \|\mathbf{x}(0)\|_Q^2 + \|\mathbf{x}\|_Q^2 + \|\mathbf{u}\|_R^2$$

Vamos agora expressar as restrições em termos de $\mathbf{x}$, $\mathbf{u}$.

As restrições podem ser escritas como

$$\mathbf{u} = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \in \mathcal{U} \times \mathcal{U} \times \cdots \times \mathcal{U}$$

$$\mathbf{x} = \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \in \mathcal{X} \times \mathcal{X} \times \cdots \times \mathcal{X}_f$$

As restrições podem ser escritas como

$$\mathbf{u} = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \in \mathcal{U} \times \mathcal{U} \times \cdots \times \mathcal{U} = \mathcal{U}^N$$

$$\mathbf{x} = \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \in \mathcal{X} \times \mathcal{X} \times \cdots \times \mathcal{X}_f$$

As restrições podem ser escritas como

$$\mathbf{u} = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \in \mathcal{U} \times \mathcal{U} \times \cdots \times \mathcal{U} = \mathcal{U}^N$$

$$\mathbf{x} = \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \in \mathcal{X} \times \mathcal{X} \times \cdots \times \mathcal{X}_f = \mathcal{X}^{N-1} \times \mathcal{X}_f$$

Lembrando que

$$\mathcal{U} = \{ u \in \mathbb{R}^p : S_u u \leq b_u \}$$

a restrição sobre $\mathbf{u}$ pode ser expressa como

$$\begin{bmatrix} S_u & 0 & \cdots & 0 \\ 0 & S_u & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & S_u \end{bmatrix} \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \leq \begin{bmatrix} b_u \\ b_u \\ \vdots \\ b_u \end{bmatrix}$$

Lembrando que

$$\mathcal{U} = \{ u \in \mathbb{R}^p : S_u u \leq b_u \}$$

a restrição sobre $\mathbf{u}$ pode ser expressa como

$$\begin{bmatrix} S_u & 0 & \cdots & 0 \\ 0 & S_u & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & S_u \end{bmatrix} \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix} \leq \begin{bmatrix} b_u \\ b_u \\ \vdots \\ b_u \end{bmatrix}$$

ou, de forma mais concisa:

$$\mathbf{S}_u \mathbf{u} \leq \mathbf{b}_u$$

sendo

$$\mathbf{S}_u = \text{diag}_N(S_u) , \quad \mathbf{b}_u = \text{col}_N(b_u)$$

De forma similar, lembrando que

$$\mathcal{X} = \{x \in \mathbb{R}^n : S_x x \leq b_x\}, \quad \mathcal{X}_f = \{x \in \mathbb{R}^n : S_f x \leq b_f\}$$

a restrição sobre $\mathbf{x}$ pode ser expressa como

$$\begin{bmatrix} S_x & 0 & \cdots & 0 \\ 0 & S_x & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & S_f \end{bmatrix} \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \leq \begin{bmatrix} b_x \\ b_x \\ \vdots \\ b_f \end{bmatrix}$$

De forma similar, lembrando que

$$\mathcal{X} = \{x \in \mathbb{R}^n : S_x x \leq b_x\}, \quad \mathcal{X}_f = \{x \in \mathbb{R}^n : S_f x \leq b_f\}$$

a restrição sobre $\mathbf{x}$ pode ser expressa como

$$\begin{bmatrix} S_x & 0 & \cdots & 0 \\ 0 & S_x & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & S_f \end{bmatrix} \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} \leq \begin{bmatrix} b_x \\ b_x \\ \vdots \\ b_f \end{bmatrix}$$

ou, de forma mais concisa:

$$\mathbf{S}_x \mathbf{x} \leq \mathbf{b}_x$$

sendo

$$\mathbf{S}_x = \begin{bmatrix} \text{diag}_{N-1}(S_x) & 0 \\ 0 & S_f \end{bmatrix}, \quad \mathbf{b}_x = \begin{bmatrix} \text{col}_{N-1}(b_x) \\ b_f \end{bmatrix}$$

Formulação do custo incluindo $\bar{x}, \bar{u}$

No caso geral em que $\bar{x} \neq 0, \bar{u} \neq 0$, o custo

$$J = \|x(N) - \bar{x}\|_{P_f}^2 + \sum_{k=0}^{N-1} \left[\|x(k) - \bar{x}\|_Q^2 + \|u(k) - \bar{u}\|_R^2 \right]$$

torna-se

$$J(\mathbf{x}, \mathbf{u}) = \|x(0) - \bar{x}\|_Q^2 + \|\mathbf{x} - \text{col}_N(\bar{x})\|_Q^2 + \|\mathbf{u} - \text{col}_N(\bar{u})\|_R^2$$

Problema de otimização

O problema de otimização a ser resolvido pode ser expresso como

$$\min_{\mathbf{x} \in \mathbb{R}^{nN}, \mathbf{u} \in \mathbb{R}^{pN}} J(\mathbf{x}, \mathbf{u})$$

sendo

$$J(\mathbf{x}, \mathbf{u}) = \|x(0) - \bar{x}\|_Q^2 + \|\mathbf{x} - \text{col}_N(\bar{x})\|_Q^2 + \|\mathbf{u} - \text{col}_N(\bar{u})\|_R^2$$

com $\mathbf{x}, \mathbf{u}$ sujeitas a

$$\mathbf{S}_x \mathbf{x} \leq \mathbf{b}_x$$

$$\mathbf{S}_u \mathbf{u} \leq \mathbf{b}_u$$

Vínculo entre $\mathbf{x}$ e $\mathbf{u}$

Vamos expressar o vínculo entre os vetores

$$\mathbf{u} = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix}$$

com base na equação de estado

$$x(k+1) = Ax(k) + Bu(k)$$

e na condição inicial $x(0)$.

Neste ponto, vale lembrar a solução da equação de estado:

$$x(k) = A^k x(0) + \sum_{i=0}^{k-1} A^{k-1-i} B u(i)$$

Neste ponto, vale lembrar a solução da equação de estado:

$$x(k) = A^k x(0) + \sum_{i=0}^{k-1} A^{k-1-i} B u(i)$$

que pode ser escrita para $k = 1, 2, \dots, N$ como

$$x(1) = A x(0) + B u(0)$$

$$x(2) = A^2 x(0) + A B u(0) + B u(1)$$

$$\vdots$$

$$x(N) = A^N x(0) + A^{N-1} B u(0) + \dots + A B u(N-2) + B u(N-1)$$

$$x(1) = Ax(0) + Bu(0)$$

$$x(2) = A^2x(0) + ABu(0) + Bu(1)$$

$$\vdots$$

$$x(N) = A^Nx(0) + A^{N-1}Bu(0) + \cdots + ABu(N-2) + Bu(N-1)$$

ou ainda

$$\begin{bmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{bmatrix} = \begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix} x(0) + \begin{bmatrix} B & 0 & \cdots & 0 \\ AB & B & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \cdots & B \end{bmatrix} \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix}$$

De forma mais concisa, vamos escrever

$$\mathbf{x} = \mathbf{A}\mathbf{x}(0) + \mathbf{B}\mathbf{u}$$

com

$$\mathbf{A} = \begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} B & 0 & \cdots & 0 \\ AB & B & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \cdots & B \end{bmatrix}$$

Retornando à função de custo

Tendo em vista o vínculo

$$\mathbf{x} = \mathbf{A}\mathbf{x}(0) + \mathbf{B}\mathbf{u}$$

pode-se reescrever a função de custo como

$$J(\mathbf{x}, \mathbf{u}) = \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_{\mathbf{Q}}^2 + \|\mathbf{x} - \text{col}_N(\bar{\mathbf{x}})\|_{\mathbf{Q}}^2 + \|\mathbf{u} - \text{col}_N(\bar{\mathbf{u}})\|_{\mathbf{R}}^2$$

Retornando à função de custo

Tendo em vista o vínculo

$$\mathbf{x} = \mathbf{A}x(0) + \mathbf{B}\mathbf{u}$$

pode-se reescrever a função de custo como

$$\begin{aligned} J(\mathbf{x}, \mathbf{u}) &= \|x(0) - \bar{x}\|_Q^2 + \|\mathbf{x} - \text{col}_N(\bar{x})\|_Q^2 + \|\mathbf{u} - \text{col}_N(\bar{u})\|_R^2 \\ &= \|x(0) - \bar{x}\|_Q^2 \\ &\quad + [\mathbf{A}x(0) + \mathbf{B}\mathbf{u} - \text{col}_N(\bar{x})]^T \mathbf{Q} [\mathbf{A}x(0) + \mathbf{B}\mathbf{u} - \text{col}_N(\bar{x})] \\ &\quad + [\mathbf{u} - \text{col}_N(\bar{u})]^T \mathbf{R} [\mathbf{u} - \text{col}_N(\bar{u})] \end{aligned}$$

$$\begin{aligned}
J(\mathbf{x}, \mathbf{u}) &= \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2 \\
&+ [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}}) + \mathbf{B}\mathbf{u}]^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}}) + \mathbf{B}\mathbf{u}] \\
&+ [\mathbf{u} - \text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} [\mathbf{u} - \text{col}_N(\bar{\mathbf{u}})]
\end{aligned}$$

$$J(\mathbf{x}, \mathbf{u}) = \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2$$

$$+ [\mathbf{Ax}(0) - \text{col}_N(\bar{\mathbf{x}}) + \mathbf{Bu}]^T \mathbf{Q} [\mathbf{Ax}(0) - \text{col}_N(\bar{\mathbf{x}}) + \mathbf{Bu}]$$

$$+ [\mathbf{u} - \text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} [\mathbf{u} - \text{col}_N(\bar{\mathbf{u}})]$$

$$= \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2 + \|\mathbf{Ax}(0) - \text{col}_N(\bar{\mathbf{x}})\|_Q^2$$

$$+ [\mathbf{Ax}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{QB}\mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{Ax}(0) - \text{col}_N(\bar{\mathbf{x}})] + \mathbf{u}^T \mathbf{B}^T \mathbf{QB}\mathbf{u}$$

$$+ \mathbf{u}^T \mathbf{R}\mathbf{u} - \mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R}\mathbf{u} + \|\text{col}_N(\bar{\mathbf{u}})\|_R^2$$

$$\begin{aligned}
J(\mathbf{x}, \mathbf{u}) = & \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2 + \|\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_Q^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_R^2 \\
& + [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} \mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \\
& - \mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \mathbf{u} + \mathbf{u}^T (\mathbf{R} + \mathbf{B}^T \mathbf{Q} \mathbf{B}) \mathbf{u}
\end{aligned}$$

Observações:

$$\begin{aligned}
J(\mathbf{x}, \mathbf{u}) = & \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_{\mathbf{Q}}^2 + \|\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_{\mathbf{Q}}^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_{\mathbf{R}}^2 \\
& + [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} \mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \\
& - \mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \mathbf{u} + \mathbf{u}^T (\mathbf{R} + \mathbf{B}^T \mathbf{Q} \mathbf{B}) \mathbf{u}
\end{aligned}$$

Observações:

- O termo constante será denotado por c_0 .

$$\begin{aligned}
J(\mathbf{x}, \mathbf{u}) = & \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_{\mathbf{Q}}^2 + \|\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_{\mathbf{Q}}^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_{\mathbf{R}}^2 \\
& + [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \\
& - \mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R}\mathbf{u} + \mathbf{u}^T (\mathbf{R} + \mathbf{B}^T \mathbf{Q}\mathbf{B})\mathbf{u}
\end{aligned}$$

Observações:

- O termo constante será denotado por c_0 .
- Lembrando que a matriz $\mathbf{Q}$ é simétrica, tem-se

$$[\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} = \left\{ \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \right\}^T$$

Como esses termos são escalares, conclui-se que são iguais entre si.

$$\begin{aligned}
J(\mathbf{x}, \mathbf{u}) = & \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_{\mathbf{Q}}^2 + \|\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_{\mathbf{Q}}^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_{\mathbf{R}}^2 \\
& + [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \\
& - \mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R}\mathbf{u} + \mathbf{u}^T (\mathbf{R} + \mathbf{B}^T \mathbf{Q}\mathbf{B})\mathbf{u}
\end{aligned}$$

Observações:

- O termo constante será denotado por c_0 .
- Lembrando que a matriz $\mathbf{Q}$ é simétrica, tem-se

$$[\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} = \left\{ \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \right\}^T$$

$$\begin{aligned}
J(\mathbf{x}, \mathbf{u}) = & \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2 + \|\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_Q^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_R^2 \\
& + [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \\
& - \mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R}\mathbf{u} + \mathbf{u}^T (\mathbf{R} + \mathbf{B}^T \mathbf{Q}\mathbf{B})\mathbf{u}
\end{aligned}$$

Observações:

- O termo constante será denotado por c_0 .
- Lembrando que a matriz $\mathbf{Q}$ é simétrica, tem-se

$$[\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} = \left\{ \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \right\}^T$$

Como esses termos são escalares, conclui-se que são iguais entre si. Logo:

$$\begin{aligned}
& [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u} + \mathbf{u}^T \mathbf{B}^T \mathbf{Q} [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] \\
& = 2 [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q}\mathbf{B}\mathbf{u}
\end{aligned}$$

De forma similar:

$$-\mathbf{u}^T \mathbf{R} [\text{col}_N(\bar{\mathbf{u}})] - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \mathbf{u} = -2 [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \mathbf{u}$$

Finalmente, pode-se escrever

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u}$$

$$+ 2 \left\{ [\mathbf{A}x(0) - \text{col}_N(\bar{x})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{u})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

com

$$c_0 = \|x(0) - \bar{x}\|_Q^2 + \|\mathbf{A}x(0) - \text{col}_N(\bar{x})\|_R^2 + \|\text{col}_N(\bar{u})\|_R^2$$

Finalmente, pode-se escrever

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u} \\ + 2 \left\{ [\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

com

$$c_0 = \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2 + \|\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_{\mathbf{R}}^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_{\mathbf{R}}^2$$

Note-se que passaremos a usar a notação $J(\mathbf{u})$ em lugar de $J(\mathbf{x}, \mathbf{u})$, uma vez que $\mathbf{x}$ foi eliminada da expressão do custo.

Finalmente, pode-se escrever

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u} \\ + 2 \left\{ [\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

com

$$c_0 = \|\mathbf{x}(0) - \bar{\mathbf{x}}\|_Q^2 + \|\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})\|_R^2 + \|\text{col}_N(\bar{\mathbf{u}})\|_R^2$$

Note-se que passaremos a usar a notação $J(\mathbf{u})$ em lugar de $J(\mathbf{x}, \mathbf{u})$, uma vez que $\mathbf{x}$ foi eliminada da expressão do custo.

Para terminar a reformulação do problema de otimização em termos de $\mathbf{u}$, deve-se considerar o vínculo entre $\mathbf{x}$ e $\mathbf{u}$ nas **restrições**.

Considerando novamente o vínculo

$$\mathbf{x} = \mathbf{A}\mathbf{x}(0) + \mathbf{B}\mathbf{u}$$

a restrição

$$\mathbf{S}_x\mathbf{x} \leq \mathbf{b}_x$$

pode ser reformulada como

$$\mathbf{S}_x\mathbf{B}\mathbf{u} \leq \mathbf{b}_x - \mathbf{S}_x\mathbf{A}\mathbf{x}(0)$$

Considerando novamente o vínculo

$$\mathbf{x} = \mathbf{A}\mathbf{x}(0) + \mathbf{B}\mathbf{u}$$

a restrição

$$\mathbf{S}_x \mathbf{x} \leq \mathbf{b}_x$$

pode ser reformulada como

$$\mathbf{S}_x \mathbf{B} \mathbf{u} \leq \mathbf{b}_x - \mathbf{S}_x \mathbf{A} \mathbf{x}(0)$$

Em conjunto com $\mathbf{S}_u \mathbf{u} \leq \mathbf{b}_u$, pode-se então expressar as restrições na forma

$$\begin{bmatrix} \mathbf{S}_x \mathbf{B} \\ \mathbf{S}_u \end{bmatrix} \mathbf{u} \leq \begin{bmatrix} \mathbf{b}_x - \mathbf{S}_x \mathbf{A} \mathbf{x}(0) \\ \mathbf{b}_u \end{bmatrix}$$

ou, de maneira mais sucinta:

$$\mathbf{S}\mathbf{u} \leq \mathbf{b}$$

com

$$\mathbf{S} = \begin{bmatrix} \mathbf{S}_x \mathbf{B} \\ \mathbf{S}_u \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \mathbf{b}_x - \mathbf{S}_x \mathbf{A}_x(0) \\ \mathbf{b}_u \end{bmatrix}$$

Problema de otimização reformulado em termos de $\mathbf{u}$

Em resumo, o problema de otimização passa a ser expresso como

$$\min_{\mathbf{u} \in \mathbb{R}^{pN}} J(\mathbf{u}) \quad \text{s.a.} \quad \mathbf{S}\mathbf{u} \leq \mathbf{b}$$

sendo

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u}$$

$$+ 2 \left\{ \left[\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}}) \right]^T \mathbf{Q} \mathbf{B} - \left[\text{col}_N(\bar{\mathbf{u}}) \right]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

Problema de otimização reformulado em termos de $\mathbf{u}$

Em resumo, o problema de otimização passa a ser expresso como

$$\min_{\mathbf{u} \in \mathbb{R}^{pN}} J(\mathbf{u}) \quad \text{s.a.} \quad \mathbf{S}\mathbf{u} \leq \mathbf{b}$$

sendo

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u}$$

$$+ 2 \left\{ \left[\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}}) \right]^T \mathbf{Q} \mathbf{B} - \left[\text{col}_N(\bar{\mathbf{u}}) \right]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

Trata-se da minimização de um **custo quadrático** sujeito a **restrições lineares**

Problema de otimização reformulado em termos de $\mathbf{u}$

Em resumo, o problema de otimização passa a ser expresso como

$$\min_{\mathbf{u} \in \mathbb{R}^{pN}} J(\mathbf{u}) \quad \text{s.a.} \quad \mathbf{S}\mathbf{u} \leq \mathbf{b}$$

sendo

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u}$$

$$+ 2 \left\{ [\mathbf{A}_x(0) - \text{col}_N(\bar{x})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{u})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

Trata-se da minimização de um **custo quadrático** sujeito a **restrições lineares**:

Problema de Programação Quadrática

Notação abreviada

Para facilitar a análise do problema de programação quadrática, passaremos a escrever o custo

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u} + 2 \left\{ [\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

nesta forma padronizada:

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + f^T \mathbf{u} + c_0$$

Notação abreviada

Para facilitar a análise do problema de programação quadrática, passaremos a escrever o custo

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u} + 2 \left\{ [\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

nesta forma padronizada:

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + f^T \mathbf{u} + c_0$$

com

$$J_{\mathbf{u}\mathbf{u}} = 2(\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}), \quad f = 2 \left\{ \mathbf{B}^T \mathbf{Q} [\mathbf{A} \mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})] - \mathbf{R} \text{col}_N(\bar{\mathbf{u}}) \right\}$$

lembrando que $\mathbf{Q}$ e $\mathbf{R}$ são simétricas.

Terminologia e notação

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + \mathbf{f}^T \mathbf{u} + c_0$$

1) A matriz $J_{\mathbf{u}\mathbf{u}}$ corresponde à chamada **Hessiana** do custo, que é definida como

$$J_{\mathbf{u}\mathbf{u}} = \begin{bmatrix} \frac{\partial^2 J}{\partial u_1^2} & \frac{\partial^2 J}{\partial u_1 \partial u_2} & \cdots & \frac{\partial^2 J}{\partial u_1 \partial u_N} \\ \frac{\partial^2 J}{\partial u_2 \partial u_1} & \frac{\partial^2 J}{\partial u_2^2} & \cdots & \frac{\partial^2 J}{\partial u_2 \partial u_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 J}{\partial u_N \partial u_1} & \frac{\partial^2 J}{\partial u_N \partial u_2} & \cdots & \frac{\partial^2 J}{\partial u_N^2} \end{bmatrix}$$

sendo $u_1, u_2, \dots, u_N$ as componentes de $\mathbf{u}$.

Terminologia e notação

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + \mathbf{f}^T \mathbf{u} + c_0$$

1) A matriz $J_{\mathbf{u}\mathbf{u}}$ corresponde à chamada **Hessiana** do custo, que é definida como

$$J_{\mathbf{u}\mathbf{u}} = \begin{bmatrix} \frac{\partial^2 J}{\partial u_1^2} & \frac{\partial^2 J}{\partial u_1 \partial u_2} & \cdots & \frac{\partial^2 J}{\partial u_1 \partial u_N} \\ \frac{\partial^2 J}{\partial u_2 \partial u_1} & \frac{\partial^2 J}{\partial u_2^2} & \cdots & \frac{\partial^2 J}{\partial u_2 \partial u_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 J}{\partial u_N \partial u_1} & \frac{\partial^2 J}{\partial u_N \partial u_2} & \cdots & \frac{\partial^2 J}{\partial u_N^2} \end{bmatrix}$$

sendo $u_1, u_2, \dots, u_N$ as componentes de $\mathbf{u}$. Vide **material suplementar 1** ao final dos slides para mais detalhes.

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{uu}} \mathbf{u} + \mathbf{f}^T \mathbf{u} + c_0$$

1) A matriz $J_{\mathbf{uu}}$ corresponde à chamada **Hessiana** do custo, que é definida como

$$J_{\mathbf{uu}} = \begin{bmatrix} \frac{\partial^2 J}{\partial u_1^2} & \frac{\partial^2 J}{\partial u_1 \partial u_2} & \cdots & \frac{\partial^2 J}{\partial u_1 \partial u_N} \\ \frac{\partial^2 J}{\partial u_2 \partial u_1} & \frac{\partial^2 J}{\partial u_2^2} & \cdots & \frac{\partial^2 J}{\partial u_2 \partial u_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 J}{\partial u_N \partial u_1} & \frac{\partial^2 J}{\partial u_N \partial u_2} & \cdots & \frac{\partial^2 J}{\partial u_N^2} \end{bmatrix}$$

sendo $u_1, u_2, \dots, u_N$ as componentes de $\mathbf{u}$. Vide **material suplementar 1** ao final dos slides para mais detalhes.

Vale notar que $J_{\mathbf{uu}} = 2(\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R})$ é simétrica e positivo definida, pois $\mathbf{Q}$ e $\mathbf{R}$ são simétricas e positivo definidas.

2) O problema de otimização será dito **factível** (“feasible”) se o conjunto

$$\mathcal{C} = \{ \mathbf{u} \in \mathbb{R}^{pN} : \mathbf{S}\mathbf{u} \leq \mathbf{b} \}$$

for não vazio.

2) O problema de otimização será dito **factível** (“feasible”) se o conjunto

$$\mathcal{C} = \{ \mathbf{u} \in \mathbb{R}^{pN} : \mathbf{S}\mathbf{u} \leq \mathbf{b} \}$$

for não vazio.

3) Nesse caso, os elementos do conjunto $\mathcal{C}$ são ditos ser soluções **viáveis** ou **factíveis** para o problema.

2) O problema de otimização será dito **factível** (“feasible”) se o conjunto

$$\mathcal{C} = \{ \mathbf{u} \in \mathbb{R}^{pN} : \mathbf{S}\mathbf{u} \leq \mathbf{b} \}$$

for não vazio.

3) Nesse caso, os elementos do conjunto $\mathcal{C}$ são ditos ser soluções **viáveis** ou **factíveis** para o problema. Vale notar que esse conjunto é **fechado**, pois as desigualdades são não estritas.

2) O problema de otimização será dito **factível** (“feasible”) se o conjunto

$$\mathcal{C} = \{ \mathbf{u} \in \mathbb{R}^{pN} : \mathbf{S}\mathbf{u} \leq \mathbf{b} \}$$

for não vazio.

3) Nesse caso, os elementos do conjunto $\mathcal{C}$ são ditos ser soluções **viáveis** ou **factíveis** para o problema. Vale notar que esse conjunto é **fechado**, pois as desigualdades são não estritas.

4) Uma solução **ótima** é um elemento $\mathbf{u}^*$ do conjunto $\mathcal{C}$ para o qual a função de custo tem o menor valor:

$$\mathbf{u}^* = \arg \min_{\mathbf{u} \in \mathcal{C}} J(\mathbf{u})$$

Mínimo na ausência de restrições

Usando a abordagem de “completar quadrados”, a função de custo

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + f^T \mathbf{u} + c_0$$

com $J_{\mathbf{u}\mathbf{u}} = J_{\mathbf{u}\mathbf{u}}^T > 0$ pode ser escrita como

$$J(\mathbf{u}) = \frac{1}{2} (J_{\mathbf{u}\mathbf{u}}^{1/2} \mathbf{u} + J_{\mathbf{u}\mathbf{u}}^{-1/2} f)^T (J_{\mathbf{u}\mathbf{u}}^{1/2} \mathbf{u} + J_{\mathbf{u}\mathbf{u}}^{-1/2} f) - \frac{1}{2} f^T J_{\mathbf{u}\mathbf{u}}^{-1} f + c_0$$

Mínimo na ausência de restrições

Usando a abordagem de “completar quadrados”, a função de custo

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{uu}} \mathbf{u} + f^T \mathbf{u} + c_0$$

com $J_{\mathbf{uu}} = J_{\mathbf{uu}}^T > 0$ pode ser escrita como

$$J(\mathbf{u}) = \frac{1}{2} (J_{\mathbf{uu}}^{1/2} \mathbf{u} + J_{\mathbf{uu}}^{-1/2} f)^T (J_{\mathbf{uu}}^{1/2} \mathbf{u} + J_{\mathbf{uu}}^{-1/2} f) - \frac{1}{2} f^T J_{\mathbf{uu}}^{-1} f + c_0$$

sendo $J_{\mathbf{uu}}^{1/2}$ uma matriz simétrica tal que (vide **material suplementar 2**)

$$J_{\mathbf{uu}}^{1/2} J_{\mathbf{uu}}^{1/2} = J_{\mathbf{uu}}$$

Mínimo na ausência de restrições

Usando a abordagem de “completar quadrados”, a função de custo

$$J(\mathbf{u}) = \frac{1}{2} \mathbf{u}^T J_{\mathbf{uu}} \mathbf{u} + f^T \mathbf{u} + c_0$$

com $J_{\mathbf{uu}} = J_{\mathbf{uu}}^T > 0$ pode ser escrita como

$$J(\mathbf{u}) = \frac{1}{2} (J_{\mathbf{uu}}^{1/2} \mathbf{u} + J_{\mathbf{uu}}^{-1/2} f)^T (J_{\mathbf{uu}}^{1/2} \mathbf{u} + J_{\mathbf{uu}}^{-1/2} f) - \frac{1}{2} f^T J_{\mathbf{uu}}^{-1} f + c_0$$

sendo $J_{\mathbf{uu}}^{1/2}$ uma matriz simétrica tal que (vide **material suplementar 2**)

$$J_{\mathbf{uu}}^{1/2} J_{\mathbf{uu}}^{1/2} = J_{\mathbf{uu}}$$

Portanto, se não houvesse restrições o menor valor de $J(\mathbf{u})$ seria obtido no ponto $\mathbf{u}^{\text{nc}}$ (nc : “non-constrained”) dado por

$$\mathbf{u}^{\text{nc}} = -J_{\mathbf{uu}}^{-1} f$$

$$\mathbf{u}^{\text{nc}} = -J_{\mathbf{uu}}^{-1}f$$

Vale salientar que esse é o ponto que anula o gradiente $J_{\mathbf{u}}$ da função (vide **material suplementar 1**):

$$J_{\mathbf{u}} = \begin{bmatrix} \frac{\partial J}{\partial u_1} \\ \frac{\partial J}{\partial u_2} \\ \vdots \\ \frac{\partial J}{\partial u_N} \end{bmatrix} = J_{\mathbf{uu}}\mathbf{u} + f$$

Os **conjuntos de nível** (“level sets”) L_α do custo são definidos como

$$L_\alpha = \{ \mathbf{u} \in \mathbb{R}^{pN} : J(\mathbf{u}) = \alpha \}$$

Os **conjuntos de nível** (“level sets”) L_α do custo são definidos como

$$L_\alpha = \{ \mathbf{u} \in \mathbb{R}^{pN} : J(\mathbf{u}) = \alpha \}$$

Para um dado nível α , o conjunto L_α é dado pelas soluções da equação

$$\frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + f^T \mathbf{u} + c_0 = \alpha$$

Os **conjuntos de nível** (“level sets”) L_α do custo são definidos como


$$L_\alpha = \{ \mathbf{u} \in \mathbb{R}^{pN} : J(\mathbf{u}) = \alpha \}$$

Para um dado nível α , o conjunto L_α é dado pelas soluções da equação

$$\frac{1}{2} \mathbf{u}^T J_{\mathbf{u}\mathbf{u}} \mathbf{u} + f^T \mathbf{u} + c_0 = \alpha$$

que, no caso em que $J_{\mathbf{u}\mathbf{u}} > 0$, correspondem à superfície de um elipsoide (uma elipse no caso $N = 2$) em torno de $\mathbf{u}^{\text{nc}}$.

Exemplo para $pN = 2$



Mínimo na presença de restrições

Na presença de restrições, o valor mínimo do custo J corresponderá ao menor valor de α para o qual a intersecção entre o conjunto de nível L_α e o conjunto de soluções factíveis $\mathcal{C}$ não é vazio:

$$J(\mathbf{u}^*) = \min \{ \alpha : L_\alpha \cap \mathcal{C} \neq \emptyset \}$$


Mínimo na presença de restrições

Na presença de restrições, o valor mínimo do custo J corresponderá ao menor valor de α para o qual a intersecção entre o conjunto de nível L_α e o conjunto de soluções factíveis $\mathcal{C}$ não é vazio:

$$J(\mathbf{u}^*) = \min \{ \alpha : L_\alpha \cap \mathcal{C} \neq \emptyset \}$$

O ponto onde se dá essa intersecção será uma solução ótima.

Exemplo para $pN = 2$



Conjunto C de soluções viáveis / factíveis

Existência de solução

Vamos supor que o conjunto $\mathcal{C}$ não seja vazio. Nesse caso, sempre existe solução ótima para o problema de programação quadrática ?

Existência de solução

Vamos supor que o conjunto $\mathcal{C}$ não seja vazio. Nesse caso, sempre existe solução ótima para o problema de programação quadrática ?

Considerando que a Hessiana J_{uu} seja positivo-definida, a resposta é sim.

Para demonstrar a existência de solução ótima, vamos considerar os chamados **conjuntos de subnível** L_{α}^{-} , definidos como

$$L_{\alpha}^{-} = \{ \mathbf{u} \in \mathbb{R}^{pN} : J(\mathbf{u}) \leq \alpha \}$$

Para demonstrar a existência de solução ótima, vamos considerar os chamados **conjuntos de subnível** L_{α}^{-} , definidos como

$$L_{\alpha}^{-} = \{ \mathbf{u} \in \mathbb{R}^{pN} : J(\mathbf{u}) \leq \alpha \}$$

Para uma função de custo **quadrática** com $J_{\mathbf{u}\mathbf{u}} > 0$, os conjuntos de subnível são elipsoides **fechados** e **limitados**.

Para demonstrar a existência de solução ótima, vamos considerar os chamados **conjuntos de subnível** L_{α}^{-} , definidos como

$$L_{\alpha}^{-} = \{ \mathbf{u} \in \mathbb{R}^{pN} : J(\mathbf{u}) \leq \alpha \}$$

Para uma função de custo **quadrática** com $J_{\mathbf{u}\mathbf{u}} > 0$, os conjuntos de subnível são elipsoides **fechados** e **limitados**. Adicionalmente, dado qualquer ponto $\mathbf{u} \in \mathbb{R}^{pN}$, existe α tal que $\mathbf{u} \in L_{\alpha}^{-}$.

Desse modo, lembrando ainda que $\mathcal{C}$ é um conjunto (por hipótese) não vazio, é possível tomar um valor de α suficientemente grande de modo que

$$\mathcal{C} \cap L_{\alpha}^{-} \neq \emptyset$$

Desse modo, lembrando ainda que $\mathcal{C}$ é um conjunto (por hipótese) não vazio, é possível tomar um valor de α suficientemente grande de modo que

$$\mathcal{C} \cap L_{\alpha}^{-} \neq \emptyset$$

Como $\mathcal{C}$ e L_{α}^{-} são fechados e L_{α}^{-} é limitado, segue que $\mathcal{C} \cap L_{\alpha}^{-}$ é um conjunto fechado e limitado.

Desse modo, lembrando ainda que $\mathcal{C}$ é um conjunto (por hipótese) não vazio, é possível tomar um valor de α suficientemente grande de modo que

$$\mathcal{C} \cap L_{\alpha}^{-} \neq \emptyset$$

Como $\mathcal{C}$ e L_{α}^{-} são fechados e L_{α}^{-} é limitado, segue que $\mathcal{C} \cap L_{\alpha}^{-}$ é um conjunto fechado e limitado.

Portanto, uma vez que a função de custo $J(\mathbf{u})$ é contínua, o **Teorema de Weierstrass** garante a existência de um ponto de mínimo $\mathbf{u}^{\alpha}$ da função no conjunto $\mathcal{C} \cap L_{\alpha}^{-}$.

Desse modo, lembrando ainda que $\mathcal{C}$ é um conjunto (por hipótese) não vazio, é possível tomar um valor de α suficientemente grande de modo que

$$\mathcal{C} \cap L_{\alpha}^{-} \neq \emptyset$$

Como $\mathcal{C}$ e L_{α}^{-} são fechados e L_{α}^{-} é limitado, segue que $\mathcal{C} \cap L_{\alpha}^{-}$ é um conjunto fechado e limitado.

Portanto, uma vez que a função de custo $J(\mathbf{u})$ é contínua, o **Teorema de Weierstrass** garante a existência de um ponto de mínimo $\mathbf{u}^{\alpha}$ da função no conjunto $\mathcal{C} \cap L_{\alpha}^{-}$.

Vale ainda notar que, para soluções viáveis $\mathbf{u}$ fora desse conjunto, os valores de $J(\mathbf{u})$ serão necessariamente maiores do que $J(\mathbf{u}^{\alpha})$, pela própria definição de L_{α}^{-} .

Desse modo, lembrando ainda que $\mathcal{C}$ é um conjunto (por hipótese) não vazio, é possível tomar um valor de α suficientemente grande de modo que

$$\mathcal{C} \cap L_{\alpha}^{-} \neq \emptyset$$

Como $\mathcal{C}$ e L_{α}^{-} são fechados e L_{α}^{-} é limitado, segue que $\mathcal{C} \cap L_{\alpha}^{-}$ é um conjunto fechado e limitado.


Portanto, uma vez que a função de custo $J(\mathbf{u})$ é contínua, o **Teorema de Weierstrass** garante a existência de um ponto de mínimo $\mathbf{u}^{\alpha}$ da função no conjunto $\mathcal{C} \cap L_{\alpha}^{-}$.

Vale ainda notar que, para soluções viáveis $\mathbf{u}$ fora desse conjunto, os valores de $J(\mathbf{u})$ serão necessariamente maiores do que $J(\mathbf{u}^{\alpha})$, pela própria definição de L_{α}^{-} .

Portanto, $\mathbf{u}^{\alpha}$ é de fato um ponto de mínimo $\mathbf{u}^*$ da função de custo.

Determinação numérica da solução ótima

Determinação numérica da solução ótima



Conjunto C de soluções viáveis / factíveis

Perguntas a serem respondidas

- 1) É possível garantir que o ponto de mínimo local assim obtido é uma solução ótima (global) ?

Perguntas a serem respondidas

- 1) É possível garantir que o ponto de mínimo local assim obtido é uma solução ótima (global) ?
- 2) A solução ótima (global) é única ?

Perguntas a serem respondidas

- 1) É possível garantir que o ponto de mínimo local assim obtido é uma solução ótima (global) ?
- 2) A solução ótima (global) é única ?

Para responder a essas perguntas, recorreremos ao conceito de **convexidade**.

Convexidade

Referência: Capítulos 2, 3 e 4 de

BOYD, S.; VANDENBERGHE, L. **Convex Optimization**. Cambridge, UK: Cambridge University Press, 2004.

web.stanford.edu/~boyd/cvxbook/

Um conjunto $\mathcal{C}$ é dito ser **convexo** se, para quaisquer $x, y \in \mathcal{C}$ e qualquer escalar λ tal que $0 \leq \lambda \leq 1$, tem-se

$$\lambda x + (1 - \lambda)y \in \mathcal{C}$$

Conjunto definido por intersecção de semiespaços

Pode-se mostrar que um conjunto $\mathcal{C}$ não vazio definido como

$$\mathcal{C} = \{x \in \mathbb{R}^M : Sx \leq b\}$$

é convexo.

Conjunto definido por intersecção de semiespaços

Pode-se mostrar que um conjunto $\mathcal{C}$ não vazio definido como

$$\mathcal{C} = \{x \in \mathbb{R}^M : Sx \leq b\}$$

é convexo.

Com efeito, dados $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$, tem-se

$$S[\lambda x + (1 - \lambda)y]$$

Conjunto definido por intersecção de semiespaços

Pode-se mostrar que um conjunto $\mathcal{C}$ não vazio definido como

$$\mathcal{C} = \{x \in \mathbb{R}^M : Sx \leq b\}$$

é convexo.

Com efeito, dados $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$, tem-se

$$S[\lambda x + (1 - \lambda)y] = \lambda Sx + (1 - \lambda)Sy$$

Conjunto definido por intersecção de semiespaços

Pode-se mostrar que um conjunto $\mathcal{C}$ não vazio definido como

$$\mathcal{C} = \{x \in \mathbb{R}^M : Sx \leq b\}$$

é convexo.

Com efeito, dados $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$, tem-se

$$S[\lambda x + (1 - \lambda)y] = \lambda Sx + (1 - \lambda)Sy \leq \lambda b + (1 - \lambda)b$$

Conjunto definido por intersecção de semiespaços

Pode-se mostrar que um conjunto $\mathcal{C}$ não vazio definido como

$$\mathcal{C} = \{x \in \mathbb{R}^M : Sx \leq b\}$$

é convexo.

Com efeito, dados $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$, tem-se

$$S[\lambda x + (1 - \lambda)y] = \lambda Sx + (1 - \lambda)Sy \leq \lambda b + (1 - \lambda)b = b$$

Conjunto definido por intersecção de semiespaços

Pode-se mostrar que um conjunto $\mathcal{C}$ não vazio definido como

$$\mathcal{C} = \{x \in \mathbb{R}^M : Sx \leq b\}$$

é convexo.

Com efeito, dados $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$, tem-se

$$S[\lambda x + (1 - \lambda)y] = \lambda Sx + (1 - \lambda)Sy \leq \lambda b + (1 - \lambda)b = b$$

Portanto $\lambda x + (1 - \lambda)y \in \mathcal{C}$.

Uma função $f : \mathcal{C} \rightarrow \mathbb{R}$ é dita ser **convexa** se $\mathcal{C}$ for um conjunto convexo e

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

para quaisquer $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$.

Uma função $f : \mathcal{C} \rightarrow \mathbb{R}$ é dita ser **convexa** se $\mathcal{C}$ for um conjunto convexo e

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

para quaisquer $x, y \in \mathcal{C}$ e $\lambda \in [0, 1]$.

A função f é dita ser **estritamente convexa** se

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y)$$

sempre que $x \neq y$ e $0 < \lambda < 1$.

Função quadrática

Pode-se mostrar que uma função $f : \mathcal{C} \rightarrow \mathbb{R}$ da forma

$$f(x) = x^T Q x + c^T x + d, \quad Q = Q^T > 0$$

é estritamente convexa.

Função quadrática

Pode-se mostrar que uma função $f : \mathcal{C} \rightarrow \mathbb{R}$ da forma

$$f(x) = x^T Q x + c^T x + d, \quad Q = Q^T > 0$$

é estritamente convexa. Com efeito, sejam $x, y \in \mathcal{C}$ e $\lambda \in \mathbb{R}$, com $x \neq y$ e $0 < \lambda < 1$. Tem-se, então:

$$f(\lambda x + (1 - \lambda)y) =$$

$$(\lambda x + (1 - \lambda)y)^T Q (\lambda x + (1 - \lambda)y) + c^T (\lambda x + (1 - \lambda)y) + d$$

Função quadrática

Pode-se mostrar que uma função $f : \mathcal{C} \rightarrow \mathbb{R}$ da forma

$$f(x) = x^T Qx + c^T x + d, \quad Q = Q^T > 0$$

é estritamente convexa. Com efeito, sejam $x, y \in \mathcal{C}$ e $\lambda \in \mathbb{R}$, com $x \neq y$ e $0 < \lambda < 1$. Tem-se, então:

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= \\ (\lambda x + (1 - \lambda)y)^T Q(\lambda x + (1 - \lambda)y) &+ c^T(\lambda x + (1 - \lambda)y) + d \\ &= \lambda^2 x^T Qx + \lambda(1 - \lambda)x^T Qy + \lambda(1 - \lambda)y^T Qx + (1 - \lambda)^2 y^T Qy \\ &\quad + \lambda c^T x + (1 - \lambda)c^T y + d \end{aligned}$$

Por outro lado:

$$\lambda f(x) + (1 - \lambda)f(y) =$$

$$\lambda(x^T Qx + c^T x + d) + (1 - \lambda)(y^T Qy + c^T y + d) =$$

Por outro lado:

$$\lambda f(x) + (1 - \lambda)f(y) =$$

$$\lambda(x^T Qx + c^T x + d) + (1 - \lambda)(y^T Qy + c^T y + d) =$$

$$\lambda x^T Qx + (1 - \lambda)y^T Qy + \lambda c^T x + (1 - \lambda)c^T y + d$$

Logo:

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) - [\lambda f(x) + (1 - \lambda)f(y)] = \\ \lambda^2 x^T Q x + \lambda(1 - \lambda)x^T Q y + \lambda(1 - \lambda)y^T Q x + (1 - \lambda)^2 y^T Q y \\ + \lambda c^T x + (1 - \lambda)c^T y + d \\ - \lambda x^T Q x - (1 - \lambda)y^T Q y - \lambda c^T x - (1 - \lambda)c^T y - d \end{aligned}$$

Logo:

$$f(\lambda x + (1 - \lambda)y) - [\lambda f(x) + (1 - \lambda)f(y)] =$$

$$\lambda^2 x^T Q x + \lambda(1 - \lambda)x^T Q y + \lambda(1 - \lambda)y^T Q x + (1 - \lambda)^2 y^T Q y$$

$$+ \lambda c^T x + (1 - \lambda)c^T y + d$$

$$- \lambda x^T Q x - (1 - \lambda)y^T Q y - \lambda c^T x - (1 - \lambda)c^T y - d$$

$$= \lambda(\lambda - 1)x^T Q x - \lambda(\lambda - 1)x^T Q y - \lambda(\lambda - 1)y^T Q x + (1 - \lambda)(-\lambda)y^T Q y$$

Logo:

$$f(\lambda x + (1 - \lambda)y) - [\lambda f(x) + (1 - \lambda)f(y)] =$$

$$\lambda^2 x^T Q x + \lambda(1 - \lambda)x^T Q y + \lambda(1 - \lambda)y^T Q x + (1 - \lambda)^2 y^T Q y$$

$$+ \lambda c^T x + (1 - \lambda)c^T y + d$$

$$- \lambda x^T Q x - (1 - \lambda)y^T Q y - \lambda c^T x - (1 - \lambda)c^T y - d$$

$$= \lambda(\lambda - 1)x^T Q x - \lambda(\lambda - 1)x^T Q y - \lambda(\lambda - 1)y^T Q x + (1 - \lambda)(-\lambda)y^T Q y$$

$$= \lambda(\lambda - 1) \left[(x - y)^T Q (x - y) \right]$$

Logo:

$$f(\lambda x + (1 - \lambda)y) - [\lambda f(x) + (1 - \lambda)f(y)] =$$

$$\lambda^2 x^T Q x + \lambda(1 - \lambda)x^T Q y + \lambda(1 - \lambda)y^T Q x + (1 - \lambda)^2 y^T Q y$$

$$+ \lambda c^T x + (1 - \lambda)c^T y + d$$

$$- \lambda x^T Q x - (1 - \lambda)y^T Q y - \lambda c^T x - (1 - \lambda)c^T y - d$$

$$= \lambda(\lambda - 1)x^T Q x - \lambda(\lambda - 1)x^T Q y - \lambda(\lambda - 1)y^T Q x + (1 - \lambda)(-\lambda)y^T Q y$$

$$= \lambda(\lambda - 1) \left[(x - y)^T Q (x - y) \right]^* \leq 0$$

$$*Q > 0, x \neq y, 0 < \lambda < 1$$

Mínimo local de uma função convexa

Seja $\mathcal{C}$ um conjunto convexo e $f : \mathcal{C} \rightarrow \mathbb{R}$ uma função convexa. Suponha que $x' \in \mathcal{C}$ seja um ponto de mínimo local de f , isto é:

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x)$$

para algum $r > 0$.

Mínimo local de uma função convexa

Seja $\mathcal{C}$ um conjunto convexo e $f : \mathcal{C} \rightarrow \mathbb{R}$ uma função convexa. Suponha que $x' \in \mathcal{C}$ seja um ponto de mínimo local de f , isto é:

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x)$$

para algum $r > 0$. Então, pode-se mostrar que x' também é um ponto de mínimo global.

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

Por absurdo, suponha que exista $x'' \in \mathcal{C}$ tal que

$$f(x'') < f(x')$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

Por absurdo, suponha que exista $x'' \in \mathcal{C}$ tal que

$$f(x'') < f(x')$$

Nesse caso, em vista de (1), tem-se

$$\|x'' - x'\| > r > 0 \quad (2)$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

Por absurdo, suponha que exista $x'' \in \mathcal{C}$ tal que

$$f(x'') < f(x')$$

Nesse caso, em vista de (1), tem-se

$$\|x'' - x'\| > r > 0 \quad (2)$$

Seja agora $y = (1 - \lambda)x' + \lambda x''$ com

$$\lambda = \frac{r}{2\|x'' - x'\|} \quad (3)$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

Por absurdo, suponha que exista $x'' \in \mathcal{C}$ tal que

$$f(x'') < f(x')$$

Nesse caso, em vista de (1), tem-se

$$\|x'' - x'\| > r > 0 \quad (2)$$

Seja agora $y = (1 - \lambda)x' + \lambda x''$ com

$$\lambda = \frac{r}{2\|x'' - x'\|} \quad (3)$$

De (2) e (3), segue que $0 < \lambda < 1$.

$$y = (1 - \lambda)x' + \lambda x''$$

$$\lambda = \frac{r}{2\|x'' - x'\|}$$

Como $\mathcal{C}$ é convexo e $0 < \lambda < 1$, tem-se que $y \in \mathcal{C}$.

$$y = (1 - \lambda)x' + \lambda x''$$

$$\lambda = \frac{r}{2\|x'' - x'\|}$$

Como $\mathcal{C}$ é convexo e $0 < \lambda < 1$, tem-se que $y \in \mathcal{C}$. Adicionalmente:

$$\|y - x'\| = \|\lambda x'' - \lambda x'\|$$

$$y = (1 - \lambda)x' + \lambda x''$$

$$\lambda = \frac{r}{2\|x'' - x'\|}$$

Como $\mathcal{C}$ é convexo e $0 < \lambda < 1$, tem-se que $y \in \mathcal{C}$. Adicionalmente:

$$\|y - x'\| = \|- \lambda x' + \lambda x''\| = \lambda \|x'' - x'\|$$

$$y = (1 - \lambda)x' + \lambda x''$$

$$\lambda = \frac{r}{2\|x'' - x'\|}$$

Como $\mathcal{C}$ é convexo e $0 < \lambda < 1$, tem-se que $y \in \mathcal{C}$. Adicionalmente:

$$\|y - x'\| = \|- \lambda x' + \lambda x''\| = \lambda \|x'' - x'\| = \frac{r}{2} < r$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

$$\|y - x'\| < r \quad (4)$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

$$\|y - x'\| < r \quad (4)$$

Como $y = (1 - \lambda)x' + \lambda x''$, com $0 < \lambda < 1$, e a função f é convexa, tem-se que

$$f(y) \leq (1 - \lambda)f(x') + \lambda \underbrace{f(x'')}_{< f(x')}$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

$$\|y - x'\| < r \quad (4)$$

Como $y = (1 - \lambda)x' + \lambda x''$, com $0 < \lambda < 1$, e a função f é convexa, tem-se que

$$f(y) \leq (1 - \lambda)f(x') + \lambda \underbrace{f(x'')}_{< f(x')} < f(x')$$

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x) \quad (1)$$

$$\|y - x'\| < r \quad (4)$$

Como $y = (1 - \lambda)x' + \lambda x''$, com $0 < \lambda < 1$, e a função f é convexa, tem-se que

$$f(y) \leq (1 - \lambda)f(x') + \lambda \underbrace{f(x'')}_{< f(x')} < f(x')$$

o que contradiz (1) e (4).

Mínimo local de uma função estritamente convexa

Seja $\mathcal{C}$ um conjunto convexo e $f : \mathcal{C} \rightarrow \mathbb{R}$ uma função estritamente convexa. Suponha que $x' \in \mathcal{C}$ seja um ponto de mínimo local de f , isto é:

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x)$$

para algum $r > 0$.

Mínimo local de uma função estritamente convexa

Seja $\mathcal{C}$ um conjunto convexo e $f : \mathcal{C} \rightarrow \mathbb{R}$ uma função estritamente convexa. Suponha que $x' \in \mathcal{C}$ seja um ponto de mínimo local de f , isto é:

$$f(x') = \min_{x \in \mathcal{C}, \|x - x'\| \leq r} f(x)$$

para algum $r > 0$. Então, se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Por absurdo, suponha que $x \neq x'$.

Se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Por absurdo, suponha que $x \neq x'$. Seja então

$$y = \lambda x + (1 - \lambda)x'$$

com $0 < \lambda < 1$.

Se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Por absurdo, suponha que $x \neq x'$. Seja então

$$y = \lambda x + (1 - \lambda)x'$$

com $0 < \lambda < 1$. Da convexidade de $\mathcal{C}$, tem-se que $y \in \mathcal{C}$.

Se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Por absurdo, suponha que $x \neq x'$. Seja então

$$y = \lambda x + (1 - \lambda)x'$$

com $0 < \lambda < 1$. Da convexidade de $\mathcal{C}$, tem-se que $y \in \mathcal{C}$. Sabendo que f é estritamente convexa, conclui-se que

$$f(y) < \lambda \underbrace{f(x)}_{f(x')} + (1 - \lambda)f(x')$$

Se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Por absurdo, suponha que $x \neq x'$. Seja então

$$y = \lambda x + (1 - \lambda)x'$$

com $0 < \lambda < 1$. Da convexidade de $\mathcal{C}$, tem-se que $y \in \mathcal{C}$. Sabendo que f é estritamente convexa, conclui-se que

$$f(y) < \lambda \underbrace{f(x)}_{f(x')} + (1 - \lambda)f(x') = f(x')$$

Se $x \in \mathcal{C}$ e $f(x) = f(x')$, pode-se mostrar que $x = x'$.

Por absurdo, suponha que $x \neq x'$. Seja então

$$y = \lambda x + (1 - \lambda)x'$$

com $0 < \lambda < 1$. Da convexidade de $\mathcal{C}$, tem-se que $y \in \mathcal{C}$. Sabendo que f é estritamente convexa, conclui-se que

$$f(y) < \lambda \underbrace{f(x)}_{f(x')} + (1 - \lambda)f(x') = f(x')$$

o que contradiz a hipótese de que x' é mínimo local (e, portanto, global) da função f .

Resumindo: Problema de otimização a ser resolvido

O problema de otimização a ser resolvido é da forma

$$\min_{\mathbf{u} \in \mathbb{R}^{pN}} J(\mathbf{u}) \quad \text{s.a.} \quad \mathbf{S}\mathbf{u} \leq \mathbf{b}$$

sendo

$$J(\mathbf{u}) = \mathbf{u}^T (\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R}) \mathbf{u} + 2 \left\{ [\mathbf{A}\mathbf{x}(0) - \text{col}_N(\bar{\mathbf{x}})]^T \mathbf{Q} \mathbf{B} - [\text{col}_N(\bar{\mathbf{u}})]^T \mathbf{R} \right\} \mathbf{u} + c_0$$

Trata-se da minimização de um **custo quadrático**, com **Hessiana positivo definida**, sujeito a **restrições lineares**:

**Problema de Programação Quadrática
(Estritamente Convexo)**

Função QUADPROG (Optimization Toolbox):

`x = quadprog(H,f,A,b)`

minimiza $0.5*x'*H*x + f'*x$

sujeito a $A*x \leq b$

Programação Quadrática no Matlab

Função QUADPROG (Optimization Toolbox):

```
x = quadprog(H,f,A,b)
minimiza 0.5*x'*H*x + f'*x
sujeito a A*x <= b
```

Em nosso caso:

$$x_{qp} = \mathbf{u}$$

$$H_{qp} = 2(\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R})$$

$$f_{qp} = 2 \left\{ \mathbf{B}^T \mathbf{Q} [\mathbf{A}x(0) - \text{col}_N(\bar{x})] - \mathbf{R} [\text{col}_N(\bar{u})] \right\}$$

$$A_{qp} = \mathbf{S}$$

$$b_{qp} = \mathbf{b}$$

Programação Quadrática no Matlab

Função QUADPROG (Optimization Toolbox):

```
x = quadprog(H,f,A,b)
minimiza 0.5*x'*H*x + f'*x
sujeito a A*x <= b
```

Em nosso caso:

$$x_{qp} = \mathbf{u}$$

$$H_{qp} = 2(\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R})$$

$$f_{qp} = 2 \left\{ \mathbf{B}^T \mathbf{Q} [\mathbf{A}x(0) - \text{col}_N(\bar{x})] - \mathbf{R} [\text{col}_N(\bar{u})] \right\}$$

$$A_{qp} = \mathbf{S}$$

$$b_{qp} = \mathbf{b}$$

Vale notar que a solução $\mathbf{u}^*$ não depende da constante c_0 na expressão do custo.

Programação Quadrática no Matlab

Função QUADPROG (Optimization Toolbox):

```
x = quadprog(H,f,A,b)
minimiza 0.5*x'*H*x + f'*x
sujeito a A*x <= b
```

Em nosso caso:

$$x_{qp} = \mathbf{u}$$

$$H_{qp} = 2(\mathbf{B}^T \mathbf{Q} \mathbf{B} + \mathbf{R})$$

$$f_{qp} = 2 \left\{ \mathbf{B}^T \mathbf{Q} [\mathbf{A}x(0) - \text{col}_N(\bar{x})] - \mathbf{R} [\text{col}_N(\bar{u})] \right\}$$

$$A_{qp} = \mathbf{S}$$

$$b_{qp} = \mathbf{b}$$

Vale notar que a solução $\mathbf{u}^*$ não depende da constante c_0 na expressão do custo. A solução também não se altera se for omitido o fator 2 em H_{qp} e f_{qp} .

Argumentos adicionais da função QUADPROG

$X = \text{QUADPROG}(H, f, A, b, Aeq, beq, LB, UB, X0, options)$

- $X = \text{QUADPROG}(H, f, A, b, Aeq, beq)$ solves the problem above while additionally satisfying the equality constraints $Aeq \cdot x = beq$.
- $X = \text{QUADPROG}(H, f, A, b, Aeq, beq, LB, UB)$ defines a set of lower and upper bounds on the design variables, X , so that the solution is in the range $LB \leq X \leq UB$. Use empty matrices for LB and UB if no bounds exist. Set $LB(i) = -\text{Inf}$ if $X(i)$ is unbounded below; set $UB(i) = \text{Inf}$ if $X(i)$ is unbounded above.
- $X0$: starting point.
- $options$: opções de otimização, incluindo algoritmo a ser usado e critérios de parada.

Opções de algoritmos:

- interior-point-convex: default
- trust-region-reflective
- active-set

Opções de algoritmos:

- interior-point-convex: default
- trust-region-reflective
- active-set

Para especificar o algoritmo a ser empregado:

```
>> options = optimset('Algorithm','active-set');  
>> quadprog(H,f,A,b,[],[],[],[],X0,options);
```



Programação Quadrática no Matlab: Exemplo

$$\min_{x_1, x_2} J = \frac{1}{2} \left[(x_1 - 5)^2 + (x_2 - 5)^2 \right]$$

s.a.

$$0 \leq x_1 \leq 2$$

$$0 \leq x_2 \leq 2$$



Custo:

$$J = \frac{1}{2} \left[(x_1 - 5)^2 + (x_2 - 5)^2 \right]$$

Custo:

$$\begin{aligned} J &= \frac{1}{2} \left[(x_1 - 5)^2 + (x_2 - 5)^2 \right] \\ &= \frac{1}{2} (x_1^2 - 10x_1 + 25 + x_2^2 - 10x_2 + 25) \end{aligned}$$

Custo:

$$\begin{aligned} J &= \frac{1}{2} \left[(x_1 - 5)^2 + (x_2 - 5)^2 \right] \\ &= \frac{1}{2} (x_1^2 - 10x_1 + 25 + x_2^2 - 10x_2 + 25) \\ &= \frac{1}{2} (x_1^2 + x_2^2) - 5x_1 - 5x_2 + 25 \end{aligned}$$

Custo:

$$\begin{aligned} J &= \frac{1}{2} \left[(x_1 - 5)^2 + (x_2 - 5)^2 \right] \\ &= \frac{1}{2} (x_1^2 - 10x_1 + 25 + x_2^2 - 10x_2 + 25) \\ &= \frac{1}{2} (x_1^2 + x_2^2) - 5x_1 - 5x_2 + 25 \\ &= \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_{H_{qp}} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \underbrace{\begin{bmatrix} -5 & -5 \end{bmatrix}}_{f_{qp}^T} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 25 \end{aligned}$$

Restrições:

$$0 \leq x_1 \leq 2$$

$$0 \leq x_2 \leq 2$$

Restrições:

$$0 \leq x_1 \leq 2$$

$$0 \leq x_2 \leq 2$$

$$x_1 \leq 2$$

$$x_2 \leq 2$$

$$-x_1 \leq 0$$

$$-x_2 \leq 0$$

Restrições:

$$0 \leq x_1 \leq 2$$

$$0 \leq x_2 \leq 2$$

$$x_1 \leq 2$$

$$x_2 \leq 2$$

$$-x_1 \leq 0$$

$$-x_2 \leq 0$$

$$\underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ -1 & 0 \\ 0 & -1 \end{bmatrix}}_{A_{qp}} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leq \underbrace{\begin{bmatrix} 2 \\ 2 \\ 0 \\ 0 \end{bmatrix}}_{b_{qp}}$$

```
>> H = eye(2);  
>> f = [-5;-5];  
>> b = [2*ones(2,1);0*ones(2,1)];  
>> A = [eye(2);-eye(2)];
```

```
>> x = quadprog(H,f,A,b)
```

Minimum found that satisfies the constraints.

Optimization completed because the objective function is non-decreasing in feasible directions, to within the value of the optimality tolerance, and constraints are satisfied to within the value of the constraint tolerance.

```
x =  
    2.0000  
    2.0000
```

Programação Quadrática: Alguns pacotes computacionais

- CVX (Matlab software for disciplined convex programming):
cvxr.com/cvx
- CVXGEN (Geração de código em C): cvxgen.com
- IPOPT (Código em C++ empregando método de pontos interiores):
www.coin-or.org/Ipopt
- QL (Código original em Fortran, traduzido posteriormente para C):
www.ai7.uni-bayreuth.de/software.htm
- CPLEX (IBM):
www-01.ibm.com/software/integration/optimization/cplex-optimizer/
- GUROBI: www.gurobi.com

Obrigado pela atenção !

Material suplementar 1: Gradiente e Hessiana da função quadrática

Seja uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$ da forma

$$f(x) = \frac{1}{2}x^T Qx + f^T x + c$$

com

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad Q = \begin{bmatrix} q_{11} & q_{12} & \cdots & q_{1n} \\ q_{21} & q_{22} & \cdots & q_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ q_{n1} & q_{n2} & \cdots & q_{nn} \end{bmatrix}, \quad f = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix}$$

$$f(x) = \frac{1}{2} \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \begin{bmatrix} q_{11} & q_{12} & \cdots & q_{1n} \\ q_{21} & q_{22} & \cdots & q_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ q_{n1} & q_{n2} & \cdots & q_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

$$+ \begin{bmatrix} f_1 & f_2 & \cdots & f_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + c$$

$$= \frac{1}{2} \left[\sum_{k=1}^n q_{k1} x_k \quad \sum_{k=1}^n q_{k2} x_k \quad \cdots \quad \sum_{k=1}^n q_{kn} x_k \right] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + \sum_{k=1}^n f_k x_k + c$$

$$f(x) = \frac{1}{2} \left(x_1 \sum_{k=1}^n q_{k1} x_k + x_2 \sum_{k=1}^n q_{k2} x_k + \cdots + x_n \sum_{k=1}^n q_{kn} x_k \right) + \sum_{k=1}^n f_k x_k + c$$

$$\frac{\partial f}{\partial x_j} = \frac{1}{2} \left(\sum_{\substack{m=1 \\ m \neq j}}^n x_m q_{jm} + \sum_{k=1}^n q_{kj} x_k + q_{jj} x_j \right) + f_j$$

$$= \frac{1}{2} \left(\sum_{m=1}^n x_m q_{jm} + \sum_{k=1}^n q_{kj} x_k \right) + f_j = \sum_{k=1}^n \frac{(q_{jk} + q_{kj}) x_k}{2} + f_j$$

Portanto:

$$\begin{aligned} f_x &= \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_N} \end{bmatrix} = \begin{bmatrix} \sum_{k=1}^n \frac{(q_{1k}+q_{k1})x_k}{2} + f_1 \\ \sum_{k=1}^n \frac{(q_{2k}+q_{k2})x_k}{2} + f_2 \\ \vdots \\ \sum_{k=1}^n \frac{(q_{nk}+q_{kn})x_k}{2} + f_n \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 2q_{11} & q_{12} + q_{21} & \cdots & q_{1n} + q_{n1} \\ q_{21} + q_{12} & 2q_{22} & \cdots & q_{2n} + q_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ q_{n1} + q_{1n} & q_{n2} + q_{2n} & \cdots & 2q_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix} \\ &= \frac{Q + Q^T}{2} x + f \end{aligned}$$

Se a matriz Q for simétrica, tem-se $f_x = Qx + f$.

$$\frac{\partial f}{\partial x_j} = \sum_{k=1}^n \frac{(q_{jk} + q_{kj})x_k}{2} + f_j$$

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \begin{cases} (q_{ji} + q_{ij})/2, & i \neq j \\ q_{jj}, & i = j \end{cases}$$

Portanto:

$$f_{xx} = (Q + Q^T)/2$$

Se a matriz Q for simétrica, tem-se

$$f_{xx} = Q$$

Material suplementar 2: Raiz quadrada matricial

Seja $Q \in \mathbb{R}^{n \times n}$ uma matriz simétrica e positivo definida, com autovetores $v_1, v_2, \dots, v_n$ (de norma unitária) associados aos autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$. Tendo em vista que $Qv_i = \lambda_i v_i$, $i = 1, 2, \dots, n$, pode-se escrever

$$Q[v_1 \ v_2 \ \cdots \ v_n] = \underbrace{[v_1 \ v_2 \ \cdots \ v_n]}_V \underbrace{\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}}_\Lambda$$

ou seja $QV = V\Lambda$.

Como $Q = Q^T \in \mathbb{R}^{n \times n}$, sabe-se que os autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$ são reais e os autovetores $v_1, v_2, \dots, v_n$ são mutuamente ortogonais.

Com efeito, se λ é um autovalor de Q associado a um autovetor v , tem-se

$$Qv = \lambda v$$

ultiplicando os dois lados dessa identidade por v^* , em que $\star$ denota o complexo-conjugado transposto, obtém-se

$$v^*Qv = v^*\lambda v = \lambda v^*v$$

Por outro lado, tem-se que $v^*Qv \in \mathbb{R}$, pois $(v^*Qv)^* = v^*Q^*v = v^*Qv$. Portanto, como $v^*v \in \mathbb{R}$, deve-se ter $\lambda \in \mathbb{R}$.

Uma prova simples da ortogonalidade entre v_i e v_j , $i \neq j$, pode ser construída para o caso particular em que $\lambda_i \neq \lambda_j$. Nesse caso, pode-se escrever

$$Qv_i = \lambda_i v_i \quad (5)$$

$$Qv_j = \lambda_j v_j \quad (6)$$

Pré-multiplicando (5) e (6) por v_j^T e v_i^T , respectivamente, tem-se

$$v_j^T Qv_i = \lambda_i v_j^T v_i \quad (7)$$

$$v_i^T Qv_j = \lambda_j v_i^T v_j \quad (8)$$

Subtraindo (8) de (7) chega-se a $(\lambda_i - \lambda_j)v_i^T v_j = 0$. Como $\lambda_i \neq \lambda_j$, por hipótese, conclui-se que $v_i^T v_j = 0$.

Para o caso de autovalores com multiplicidade maior do que um, ver Gantmacher (1990, v. 1, p. 270-272).

GANTMACHER, F. R. **The Theory of Matrices**, 2 ed. New York: Chelsea, 1990.

Como $v_1, v_2, \dots, v_n$ possuem norma unitária e são mutuamente ortogonais, tem-se que

$$V^T V = V V^T = I$$

sendo I uma matriz identidade.

Portanto, pós-multiplicando os dois lados de

$$QV = V\Lambda$$

por V^T , tem-se que

$$QVV^T = V\Lambda V^T \Rightarrow Q = V\Lambda V^T$$

sendo

$$V = [v_1 \ v_2 \ \cdots \ v_n], \ \Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

$$Q = V\Lambda V^T, \quad V = [v_1 \ v_2 \ \cdots \ v_n], \quad \Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

Como $Q > 0$, todos os autovalores são positivos. Portanto, a matriz definida como

$$Q^{1/2} = V \begin{bmatrix} \sqrt{\lambda_1} & 0 & \cdots & 0 \\ 0 & \sqrt{\lambda_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \cdots & \sqrt{\lambda_n} \end{bmatrix} V^T$$

é simétrica, positivo definida e satisfaz

$$Q^{1/2} Q^{1/2} = Q$$